UCAB Universidad Católica ANDRÉS BELLO

Informe Técnico
Equipo 05

Versión 1.0

Histórico de Revisiones

Fecha	Versión	Descripción	Autor(es)
26/10/2026	*1.0*	*Se realizó el informe técnico.*	*Daniel Verschuur* *Edgar Paz* *Javier Delmoral* *Valeria Leon* *Gilberto Moncada*

© UCAB, 2026

Tabla de Contenidos

A1 - Preparación y Auditoría de Calidad de Datos **4**

A2 - Análisis de Rentabilidad y Comportamiento de Compra **16**

A3 - Detección de Fugas de Ingresos **24**

A4 - Evaluación de la Efectividad del Marketing **34**

A5 - Storytelling Ejecutivo y Recomendaciones **41**

Informe Técnico

El presente informe técnico expone la auditoría de datos, el modelado dimensional y el análisis exploratorio integral desarrollado para **RetailVenture C.A.** La organización atraviesa una fase de estrechamiento de márgenes caracterizada por una reducción interanual del 8% en el ticket promedio, un incremento en la tasa de devoluciones alcanzando el 14% en el último trimestre y una contracción en la efectividad de conversión de marketing del 22% al 11% en un período de 18 meses.

El objetivo fundamental de este trabajo es identificar las causas raíz de estas ineficiencias operativas a partir de la integración y procesamiento de 24 meses de historia operativa, transformando datos crudos en un storytelling con sustento técnico y valor estratégico para la toma de decisiones gerenciales.

Los resultados se obtuvieron de los notebooks Jupyter realizados con python que se encuentran adjuntos en la carpeta de proyecto.

A1 - Preparación y Auditoría de Calidad de Datos

Lo primero que se realizó fue la carga de los datasets y su perfilado, esto con el objetivo de conocer la forma de cada uno de ellos (tamaño, tipos, nulos, cardinalidad) antes de juzgar la calidad de los mismos. Todo esto se realizó con Python y librerías para el manejo de datos y gráficas como lo son Pandas, Matplotlib, numpy y scipy.

Primero vemos unos datos generales sobre cada dataset

	filas	columnas	memoria_KB
clientes	8000	7	2477
transacciones	50000	10	16248
productos	318	7	86
devoluciones	6724	6	1694
interacciones_crm	4684	7	1402
campanas_marketing	8820	8	2307

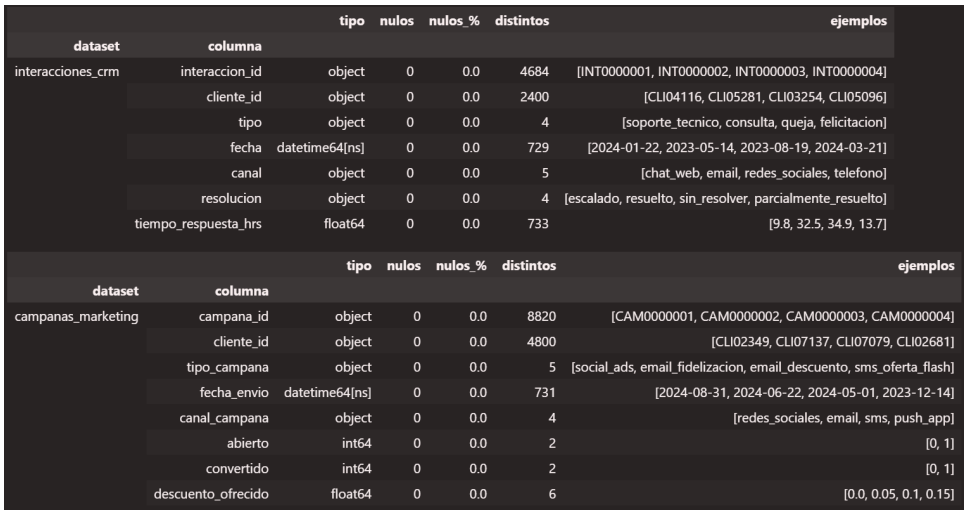
Posteriormente pasamos a describir cada dataset de una manera más precisa, buscando valores **nulos**.

dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
clientes	cliente_id	object	0	0.0	8000	[CLI00001, CLI00002, CLI00003, CLI00004]
	edad	int64	0	0.0	55	[65, 23, 19, 55]
	genero	object	0	0.0	3	[M, F, No especificado]
	ciudad	object	0	0.0	8	[Caracas, Valencia, Mérida, Puerto La Cruz]
	segmento	object	0	0.0	5	[Esporádico, Frecuente, Premium, Inactivo]
	fecha_registro	datetime64[ns]	0	0.0	730	[2023-01-26, 2024-07-12, 2024-09-08, 2024-04-04]
	canal_adquisicion	object	0	0.0	6	[Tienda_física, Orgánico_web, Referido, Email_campaña]

dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
transacciones	transaccion_id	object	0	0.0	50000	[TRX0000001, TRX0000002, TRX0000003, TRX0000004]
	cliente_id	object	0	0.0	7608	[CLI03713, CLI07240, CLI00568, CLI06802]
	fecha	datetime64[ns]	0	0.0	731	[2024-01-11, 2023-08-27, 2024-07-20, 2024-04-02]
	producto_id	object	0	0.0	318	[PRD0189, PRD0219, PRD0306, PRD0262]
	cantidad	int64	0	0.0	5	[1, 2, 4, 3]
	precio_unitario	float64	0	0.0	317	[6.72, 340.03, 33.94, 268.47]
	descuento	float64	0	0.0	311	[0.044, 0.077, 0.116, 0.063]
	monto_neto	float64	0	0.0	24840	[6.42, 313.85, 60.01, 251.56]
	canal	object	0	0.0	3	[tienda_fisica, online, app_movil]
	metodo_pago	object	0	0.0	5	[efectivo, tarjeta_credito, tarjeta_debito, transferencia]

dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
productos	producto_id	object	0	0.0	318	[PRD0001, PRD0002, PRD0003, PRD0004]
	nombre	object	0	0.0	318	[Electrónica_Prod_0001, Electrónica_Prod_0002, Electrónica_Prod_0003, Electrónica_Prod...
	categoria	object	0	0.0	6	[Electrónica, Ropa_y_Calzado, Hogar_y_Deco, Alimentos_y_Bebidas]
	subcategoria	object	0	0.0	24	[Smartphones, Computadoras, Audio, Accesorios_tech]
	costo	float64	0	0.0	318	[936.26, 503.65, 367.79, 712.66]
	precio_lista	float64	0	0.0	317	[1186.64, 566.54, 439.42, 821.04]
	margen_bruto_pct	float64	0	0.0	223	[21.1, 11.1, 16.3, 13.2]

dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
devoluciones	devolucion_id	object	0	0.0	6724	[DEV000001, DEV000002, DEV000003, DEV000004]
	transaccion_id	object	0	0.0	6724	[TRX0000015, TRX0000020, TRX0000021, TRX0000022]
	cliente_id	object	0	0.0	3679	[CLI03995, CLI07310, CLI07961, CLI00809]
	motivo	object	0	0.0	7	[No_cumple_expectativas, Producto_defectuoso, Error_en_pedido, Fraude_reportado]
	monto_devuelto	float64	0	0.0	5240	[57.68, 1030.45, 753.14, 129.64]
	fecha_devolucion	datetime64[ns]	0	0.0	727	[2024-08-04, 2024-06-30, 2024-07-07, 2024-01-21]



dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
interacciones_crm	interaccion_id	object	0	0.0	4684	[INT0000001, INT0000002, INT0000003, INT0000004]
	cliente_id	object	0	0.0	2400	[CLI04116, CLI05281, CLI03254, CLI05096]
	tipo	object	0	0.0	4	[soporte_tecnico, consulta, queja, felicitacion]
	fecha	datetime64[ns]	0	0.0	729	[2024-01-22, 2023-05-14, 2023-08-19, 2024-03-21]
	canal	object	0	0.0	5	[chat_web, email, redes_sociales, telefono]
	resolucion	object	0	0.0	4	[escalado, resuelto, sin_resolver, parcialmente_resuelto]
	tiempo_respuesta_hrs	float64	0	0.0	733	[9.8, 32.5, 34.9, 13.7]

dataset	columna	tipo	nulos	nulos_%	distintos	ejemplos
campanas_marketing	campana_id	object	0	0.0	8820	[CAM0000001, CAM0000002, CAM0000003, CAM0000004]
	cliente_id	object	0	0.0	4800	[CLI02349, CLI07137, CLI07079, CLI02681]
	tipo_campana	object	0	0.0	5	[social_ads, email_fidelizacion, email_descuento, sms_oferta_flash]
	fecha_envio	datetime64[ns]	0	0.0	731	[2024-08-31, 2024-06-22, 2024-05-01, 2023-12-14]
	canal_campana	object	0	0.0	4	[redes_sociales, email, sms, push_app]
	abierto	int64	0	0.0	2	[0, 1]
	convertido	int64	0	0.0	2	[0, 1]
	descuento_ofrecido	float64	0	0.0	6	[0.0, 0.05, 0.1, 0.15]

Como se demuestra en las imágenes, ninguno de los seis datasets presentan nulos explícitos. Procedemos a buscar nulos disfrazados, que son aquellos valores que ocupan la celda pero no aportan información (`No especificado`, cadenas vacías, `N/A`, espacios sobrantes).

Con esta búsqueda exhaustiva encontramos que en el dataset de clientes hay 433 registros con género 'No especificado'. Ya que el género no se puede inferir sin introducir un sesgo en los datos se decide mantener como una categoría separada.

Luego se procedió a la búsqueda de **duplicados**, la cual tiene como objetivo detectar registros repetidos en tres niveles de exigencia:

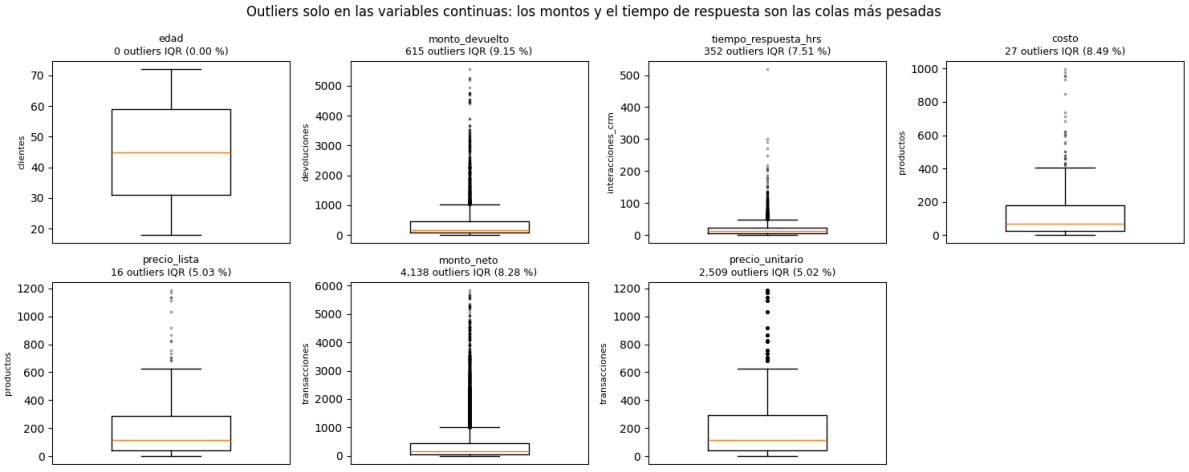
1. Clave primaria duplicada: El identificador se repite.
2. Fila idéntica: todas las columnas iguales.
3. Duplicado lógico: Distinto ID pero mismo hecho de negocio, según una clave natural definida por dataset.

	dataset	registros	pk_duplicada	filas_identicas	dup_logicos	clave_logica
0	clientes	8000	0	0	0	—
1	transacciones	50000	0	0	0	cliente_id, fecha, producto_id, cantidad, monto_neto, canal
2	productos	318	0	0	0	nombre
3	devoluciones	6724	0	0	0	transaccion_id
4	interacciones_crm	4684	0	0	0	cliente_id, tipo, fecha, canal
5	campanas_marketing	8820	0	0	1	cliente_id, tipo_campana, fecha_envio

No hay claves primarias repetidas ni filas idénticas en ningún dataset, así que el riesgo de doble conteo por error de carga es nulo. Solo aparece 1 duplicado lógico en campanas_marketing, investigando a profundidad se trata de un cliente que recibió dos email_descuento el mismo día con descuentos distintos (15 % y 5 %) y solo convirtió el segundo. Como tienen ID, descuento y resultado distintos, no es una fila repetida por error, así que se conservan los dos y se marca con un flag_envio_duplicado.

Ahora procedemos con la búsqueda de **outliers**, esto con el objetivo de buscar valores extremos solo donde la medida tiene sentido. Se hizo uso de distintos tratamientos según el tipo de variable.

Tipo de variable	Variables	Tratamiento
Cuantitativa **continua**	`edad`, `precio_unitario`, `monto_neto`, `costo`, `precio_lista`, `monto_devuelto`, `tiempo_respuesta_hrs`	Resumen, **IQR** y **z-score**, boxplot
Cuantitativa **acotada**	`descuento` [0,1), `margen_bruto_pct` [0,100]	Validación de rango; sin z-score
Conteo / ordinal	`cantidad` (1–5), `descuento_ofrecido` (6 niveles)	Tabla de frecuencias
Binaria	`abierto`, `convertido`	Proporción de eventos
Nominal / fecha / ID	resto	Dominio (§1.1), reglas temporales (§4)



Un outlier estadístico no es un error. Así que contrastamos cada uno con la identidad aritmética de la venta. Por ejemplo si el monto reconstruido precio × cantidad × (1 − descuento) coincide con monto_neto, es una venta real de un producto caro. A continuación las decisiones para cada outlier.

Variable	Diagnóstico	Decisión
`monto_neto`, `precio_unitario`, `monto_devuelto`, `costo`, `precio_lista`	Muy asimétricas a la derecha. Los outliers del IQR se concentran en Electrónica y **su monto cuadra exactamente** con precio × cantidad × (1 − descuento): son ventas reales de productos caros, no errores de carga.	**Se conservan.** Se marcan con `flag_outlier_monto`; en los análisis de A2 se reporta la mediana junto a la media.
`tiempo_respuesta_hrs`	Distribución con cola larga; los valores altos son casos escalados (positivos y plausibles), no errores.	**Se conservan:** son señal de mal servicio, justo lo que analiza A3. Se marca el incumplimiento del SLA (`flag_respuesta_extrema`) y se crea una versión *winsorizada* para los promedios.
`edad`	Dentro del rango plausible (18–72 años).	Sin acción.
`descuento`, `margen_bruto_pct`	Dentro de su rango válido. Sin z-score por tener soporte acotado.	Sin acción.
`cantidad`, `descuento_ofrecido`	`cantidad` toma 1–5 unidades. `descuento_ofrecido` son 6 niveles de diseño. Un valor alto es la cola del conteo, no un dato anómalo.	Sin acción ni marca.
`abierto`, `convertido`	Proporciones (variables binarias).	Sin acción.

Posteriormente se revisó la existencia de registros inconsistentes, esto se realizó mediante dos métodos. La integridad referencial (claves foráneas) y verificaciones de consistencia (R01–R25). Estas verificaciones de consistencia son un conjunto de reglas, no dictadas por la empresa, que representan nuestra manera de formar el criterio operativo con el que se mide la dimensión de consistencia del punto 5.

#	**Dataset**	**Verificación (el registro cumple si…)**	**Dimensión**
R01	clientes	edad entre 18 y 100	decisión de negocio
R02	clientes	fecha de alta dentro del período	estructural/aritmética
R03	clientes	fecha de alta ≤ primera compra	temporal (fecha_registro)
R04	transacciones	precio_unitario = precio_lista del catálogo	estructural/aritmética
R05	transacciones	monto_neto = cant × precio × (1 − desc)	estructural/aritmética
R06	transacciones	cantidad > 0 y descuento en [0, 1)	estructural/aritmética
R07	transacciones	fecha de compra ≥ fecha de alta del cliente	temporal (fecha_registro)
R08	productos	costo < precio_lista	estructural/aritmética
R09	productos	margen_bruto_pct = (precio − costo)/precio (±0.1 pp)	estructural/aritmética
R10	devoluciones	cliente coincide con el de la transacción	estructural/aritmética

R11	devoluciones	fecha_devolucion ≥ fecha de compra	estructural/aritmética
R12	devoluciones	monto_devuelto ≤ monto_neto	estructural/aritmética
R13	devoluciones	motivo "Talla_incorrecta" solo en Ropa_y_Calzado	decisión de negocio
R14	interacciones_crm	tiempo_respuesta_hrs > 0	estructural/aritmética
R15	interacciones_crm	felicitación sin estado de resolución	decisión de negocio
R16	interacciones_crm	fecha ≥ fecha de alta del cliente	temporal (fecha_registro)
R17	campanas_marketing	canal coherente con tipo de campaña	decisión de negocio
R18	campanas_marketing	convertido ⇒ abierto	estructural/aritmética
R19	campanas_marketing	convertido ⇒ compra en ≤30 días tras el envío	decisión de negocio
R20	campanas_marketing	fecha_envio ≥ fecha de alta del cliente	temporal (fecha_registro)
R21	campanas_marketing	descuento ofrecido = descuento aplicado (conversión verificable)	decisión de negocio
R22	devoluciones	devolución por el monto completo de la línea	decisión de negocio
R23	devoluciones	días a devolución entre 0 y 30	decisión de negocio

R24	transacciones	sin casi-duplicados (cliente, fecha, producto)	decisión de negocio
R25	transacciones, devoluciones, interacciones_crm, campanas_marketing	fecha dentro de la ventana de análisis	estructural/aritmética

- 12 estructurales o aritméticas (R02, R04–R06, R08–R12, R14, R18, R25): se deducen del diccionario de campos del enunciado y de la aritmética del negocio, no requieren juicio.

- 4 temporales sobre fecha_registro (R03, R07, R16, R20): su validez depende de qué signifique ese campo, y el propio dato la contradice, por eso la limpieza lo sustituye por 'fecha_alta_efectiva'.

- 9 con una decisión de negocio (R01, R13, R15, R17, R19, R21, R22, R23, R24): cinco dependen de constantes visibles en la definición de parámetros (edad 18–100, mapa canal↔tipo de campaña, ventana de atribución, tolerancia de descuento y plazo de devolución) y el resto se apoya en la semántica del campo (una felicitación no tiene resolución; no hay talla fuera de ropa; una devolución es por el monto completo de la línea).

A continuación el resultado de esta auditoría:

	dataset	categoria	regla	aplicables	incumplen	%_cumple
0	clientes	decisión de negocio	R01 edad entre 18 y 100	8000	0	100.00
1	clientes	estructural/aritmética	R02 fecha de alta dentro del período	8000	0	100.00
2	clientes	temporal (fecha_registro)	R03 fecha de alta ≤ primera compra	8000	5803	27.46
3	transacciones	estructural/aritmética	R04 precio_unitario = precio_lista del catálogo	50000	0	100.00
4	transacciones	estructural/aritmética	R05 monto_neto = cant × precio × (1 − desc)	50000	0	100.00
5	transacciones	estructural/aritmética	R06 cantidad > 0 y descuento en [0, 1)	50000	0	100.00
6	transacciones	temporal (fecha_registro)	R07 fecha de compra ≥ fecha de alta del cliente	50000	24972	50.06
7	transacciones	decisión de negocio	R24 sin casi-duplicados (cliente, fecha, producto)	50000	0	100.00
8	transacciones	estructural/aritmética	R25 fecha dentro de la ventana de análisis	50000	0	100.00
9	productos	estructural/aritmética	R08 costo < precio_lista	318	0	100.00
10	productos	estructural/aritmética	R09 margen_bruto_pct = (precio − costo)/precio (±0.1 pp)	318	0	100.00
11	devoluciones	estructural/aritmética	R10 cliente coincide con el de la transacción	6724	0	100.00
12	devoluciones	estructural/aritmética	R11 fecha_devolucion ≥ fecha de compra	6724	0	100.00
13	devoluciones	estructural/aritmética	R12 monto_devuelto ≤ monto_neto	6724	0	100.00
14	devoluciones	decisión de negocio	R13 motivo "Talla_incorrecta" solo en Ropa_y_Calzado	6724	0	100.00
15	devoluciones	decisión de negocio	R22 devolución por el monto completo de la línea	6724	0	100.00
16	devoluciones	decisión de negocio	R23 días a devolución entre 0 y 30	6724	0	100.00
17	devoluciones	estructural/aritmética	R25 fecha dentro de la ventana de análisis	6724	0	100.00
18	interacciones_crm	estructural/aritmética	R14 tiempo_respuesta_hrs > 0	4684	0	100.00
19	interacciones_crm	decisión de negocio	R15 felicitación sin estado de resolución	4684	233	95.03
20	interacciones_crm	temporal (fecha_registro)	R16 fecha ≥ fecha de alta del cliente	4684	2428	48.16
21	interacciones_crm	estructural/aritmética	R25 fecha dentro de la ventana de análisis	4684	0	100.00

22	campanas_marketing	decisión de negocio	R17 canal coherente con tipo de campaña	8820	0	100.00
23	campanas_marketing	estructural/aritmética	R18 convertido ⇒ abierto	8820	0	100.00
24	campanas_marketing	decisión de negocio	R19 convertido ⇒ compra en ≤30 días tras el envío	8820	618	92.99
25	campanas_marketing	temporal (fecha_registro)	R20 fecha_envio ≥ fecha de alta del cliente	8820	4421	49.88
26	campanas_marketing	decisión de negocio	R21 descuento ofrecido = descuento aplicado (conversión verificable)	179	166	7.26
27	campanas_marketing	estructural/aritmética	R25 fecha dentro de la ventana de análisis	8820	0	100.00

La siguiente tabla demuestra la lectura de las inconsistencias vistas en la ejecución de la auditoría.

Verificación	Qué se midió	Resultado
R07 y R03	desfase de `fecha_registro`	**24.972 de 50.000** compras (49,9 %) anteriores al alta declarada, con retraso mediano de **216 días** y máximo de 728; **5.803 de 7.608** clientes compradores compraron antes de su registro
R19	conversiones declaradas	**797** declaradas; solo **179 (22,5 %)** tienen compra dentro de los 30 días; **184** no tienen ninguna compra posterior y **434** la tienen más tarde que la ventana
R21	descuento ofrecido vs. aplicado	coincide en **13 de las 179** conversiones verificables (7,3 %)
R22	devolución por el monto completo	**0** incumplimientos de 6.724 devoluciones
R23	plazo de devolución	mediana **15** días y máximo **30**, **0** fuera de [0, 30]
R24	casi-duplicados (cliente, fecha, producto)	**0** en 50.000 ventas

	R07 · compras anteriores al alta	R03 · clientes con compra previa al alta
casos	24972	5803
denominador	50,000 compras	7,608 compradores
retraso mediano (días)	216	—
retraso máximo (días)	728	—

	conversiones declaradas	con compra en ≤30 días	sin compra posterior	con compra fuera de la ventana
casos	797	179	184	434

	dataset	regla	aplicables	incumplen	%_cumple
6	transacciones	R07 fecha de compra ≥ fecha de alta del cliente	50000	24972	50.06
2	clientes	R03 fecha de alta ≤ primera compra	8000	5803	27.46
25	campanas_marketing	R20 fecha_envio ≥ fecha de alta del cliente	8820	4421	49.88
20	interacciones_crm	R16 fecha ≥ fecha de alta del cliente	4684	2428	48.16
24	campanas_marketing	R19 convertido ⇒ compra en ≤30 días tras el envío	8820	618	92.99
19	interacciones_crm	R15 felicitación sin estado de resolución	4684	233	95.03
26	campanas_marketing	R21 descuento ofrecido = descuento aplicado (conversión verificable)	179	166	7.26

Concluimos las inconsistencias de la siguiente manera:

- clientes.fecha_registro no guarda relación con la actividad real. Alrededor de la mitad de las compras son anteriores a la fecha de registro, y el adelanto se reparte de forma casi uniforme (no es un desfase fijo de zona horaria ni de formato). Es la única causa de R03, R07, R16 y R20, y explica por sí sola casi toda la pérdida de consistencia del §5. Decisión: no se eliminan esas filas porque se perdería la mitad de las ventas, se marca 'flag_antes_registro' y se deriva 'fecha_alta_efectiva' = mín(fecha_registro, primer evento observado).

- 'convertido' no es verificable contra las transacciones. Solo una minoría de las conversiones declaradas tiene una compra del cliente dentro de los 30 días posteriores al envío, y hay campañas marcadas como *no convertidas* con compra inmediata. Decisión: Se conserva 'convertido' como métrica oficial del negocio y se añade 'flag_conversion_verificada' para poder calcular el retorno con compras reales (§6).

- R21: El descuento que la campaña dice ofrecer casi nunca coincide con el descuento aplicado en la compra posterior. No se puede asumir que una compra posterior usó ese descuento: el costo implícito de la campaña debe calcularse con el descuento ofrecido y declararse como supuesto.

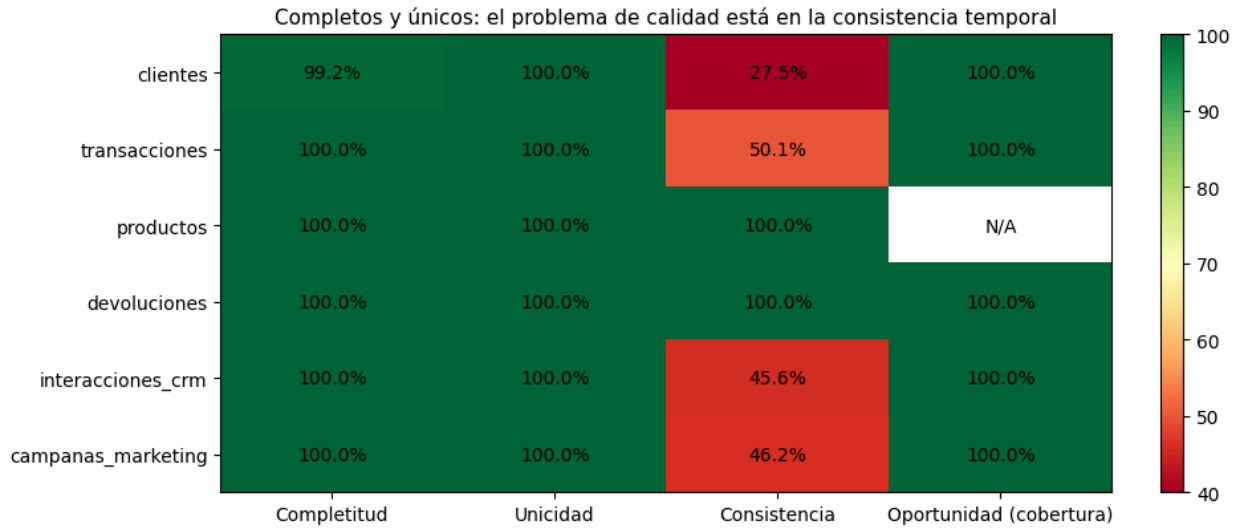
- R22–R24 confirman supuestos: Todas las devoluciones son por el monto completo de la línea y dentro del plazo de 30 días, y no hay casi-duplicados. Por eso 'monto_devuelto' se puede usar sin ajustes en el margen neto.

Métricas de calidad por dataset

A continuación presentamos las 4 métricas con las que medimos la calidad de los datasets.

Métrica	Definición operativa
Completitud	1 − (celdas nulas + nulos disfrazados) / celdas totales
Unicidad	1 − (registros con PK duplicada + duplicados lógicos) / registros
Consistencia	% de registros que cumplen todas las verificaciones de su dataset (integridad referencial + R01–R25). Se reporta también sin las reglas de fecha de alta (R02, R03, R07, R16, R20) para aislar el efecto de ese único atributo

Oportunidad	Se descompone en cobertura (% de fechas dentro de la ventana), latencia (% que cumple el SLA de su proceso: devolución ≤ 30 d, respuesta CRM ≤ 168 h) y frescura (días entre el último evento y la fecha de corte). No aplica a productos, que no tiene fecha de evento: N/A por diseño



Se aprecia en la siguiente imagen el cálculo de las métricas para cada dataset donde se hace hincapié en los siguientes aspectos:

- Completitud y unicidad: prácticamente 100 % en los seis datasets. No hay nulos explícitos, el único nulo disfrazado es género = "No especificado"` (que se conserva como categoría) y no hay claves repetidas ni duplicados lógicos salvo el doble envío de campaña.

- Consistencia: Es la dimensión que falla. Casi toda la brecha la produce un solo atributo, `clientes.fecha_registro`, que contamina clientes, transacciones, CRM y campañas. Al excluir las reglas de fecha de alta, todos los datasets suben a ~95 % o más, salvo campañas, que sigue penalizada por R19 y R21 (conversiones no verificables y descuentos que no coinciden).

- Oportunidad: La cobertura es total (todas las fechas caen dentro de la ventana 2023-01-01 – 2024-12-31) y la frescura es de 0 días en los cuatro datasets con eventos. Lo que falla es la latencia: una parte de las devoluciones y de las respuestas de CRM incumple su SLA, que es precisamente lo que analiza A3.

- Conclusión: Los datos sirven para el análisis, pero hay que tratar con cautela dos campos (‘fecha_registro’ y ‘convertido’) y marcar los casos que incumplen SLA. Ninguna decisión de A2–A4 debería apoyarse en ‘fecha_registro’ en bruto.

Limpieza y transformación

Con estos resultados sobre la calidad de los datasets tenemos buscamos producir las tablas limpias que consumen los siguientes análisis sin perder registros y dejando cada decisión explícita. La limpieza solo (i) marca lo dudoso con flag, (ii) corrige las inconsistencia semánticas demostrables (felicitaciones con estado de resolución) y (iii) deriva las columnas que el análisis necesita. Los datasets crudos no se tocan: se trabaja sobre copias.

Validación de la transformación. Antes de medir el efecto de la limpieza, las aserciones de la celda anterior comprueban que no se pierde ni se duplica ningún registro y que los montos concilian con el origen.

Qué cambia y qué no: De las 7 verificaciones que fallaban en el crudo, 5 desaparecen al evaluarlas contra 'fecha_alta_efectiva' o al corregir la semántica de las felicitaciones: R03 (5.803 → 0), R07 (24.972 → 0), R15 (233 → 0), R16 (2.428 → 0) y R20 (4.421 → 0). La consistencia de 'clientes' y de 'transacciones' pasa de 27,46 % y 50,06 % a 100 %.

Las dos que persisten no son un defecto de la limpieza, sino del dato de origen: R19 (618 conversiones declaradas sin compra atribuible) y R21 (166 conversiones cuyo descuento aplicado no coincide con el ofrecido). Corregirlas exigiría inventar información, así que se quedan visibles y marcadas con 'flag_conversion_verificada'. Las dos tablas siguientes muestran primero las que cambian y después las que siguen fallando.

	dataset	regla	incumplen_antes	incumplen_despues
2	clientes	R03 fecha de alta ≤ primera compra	5803	0
6	transacciones	R07 fecha de compra ≥ fecha de alta del cliente	24972	0
19	interacciones_crm	R15 felicitación sin estado de resolución	233	0
20	interacciones_crm	R16 fecha ≥ fecha de alta del cliente	2428	0
25	campanas_marketing	R20 fecha_envio ≥ fecha de alta del cliente	4421	0

	dataset	regla	incumplen
24	campanas_marketing	R19 convertido ⇒ compra en ≤30 días tras el envío	618
26	campanas_marketing	R21 descuento ofrecido = descuento aplicado (conversión verificable)	166

Lectura: la mejora se concentra donde las verificaciones de fecha_de_alta pasan a evaluarse contra fecha_alta_efectiva (clientes, transacciones, CRM y campañas). Lo que no mejora, R19 y R21 en campañas, es una limitación del dato de origen que se documenta y se marca, no se corrige: esa es la diferencia entre limpiar y maquillar. La completitud y la unicidad no cambian porque no se imputa ni se elimina ningún registro.

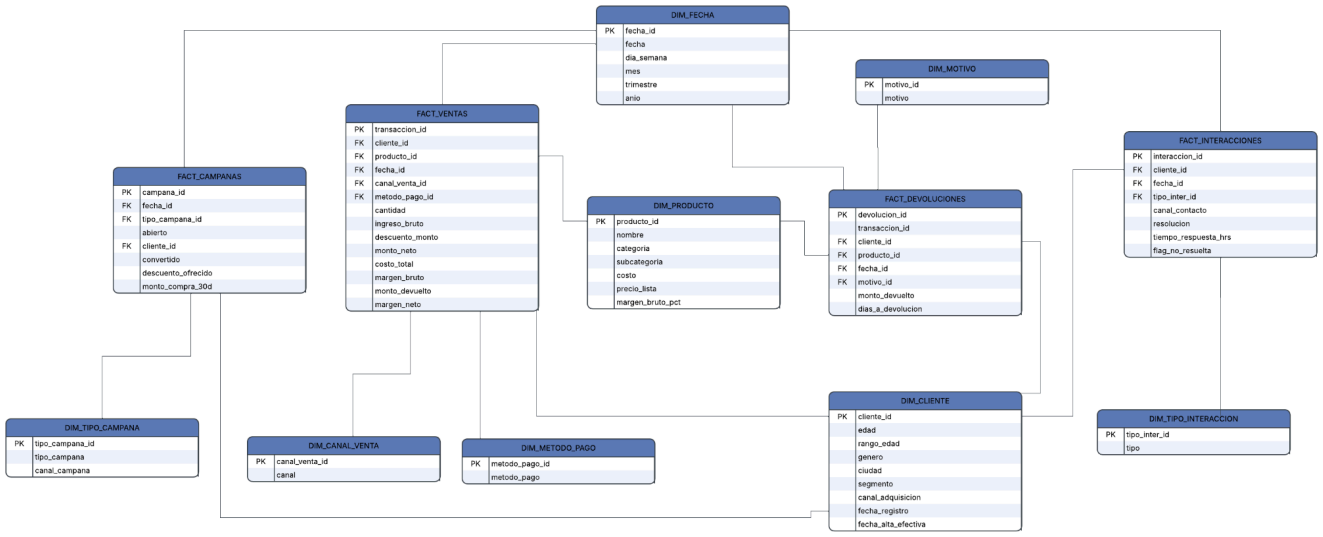
A continuación las decisiones de limpieza:

	dataset	problema	decisión	justificación	verificación
0	clientes	genero = "No especificado" (433; 5.4%)	Conservar como categoría propia; no imputar	No es inferible desde otras variables; imputar introduciría un sesgo.	Se conserva como nivel propio en dim_cliente y A2 lo trata como una categoría más.
1	clientes	fecha_registro posterior a la primera compra (5,803 clientes)	Conservar; crear fecha_alta_efectiva = mín(registro, primer evento) y antiguedad_dias	Eliminar invalidaría ~la mitad de las ventas; la actividad transaccional es más confia...	assert fecha_alta_efectiva ≤ fecha_registro; con el alta efectiva R03/R07/R16/R20 deja...
2	clientes	392 clientes sin compras	Conservar; flag_sin_compras	Son relevantes para marketing (reciben campañas) y para el análisis de churn.	len(dim_cliente) = len(clientes).
3	transacciones	24,972 compras anteriores a fecha_registro	Conservar; flag_antes_registro	El error está en el atributo del cliente, no en la transacción.	dim_producto/fact_ventas conservan todas las filas (§7).
4	transacciones	Outliers de monto_neto por IQR (4,138)	Conservar; flag_outlier_monto	Ventas legítimas de alto valor (sobre todo Electrónica); el monto reconstruido cuadra ...	Todos los outliers cumplen R05 (§3.2).
5	transacciones	Variables derivadas de rentabilidad	ingreso_bruto, descuento_monto, costo_total, margen_bruto, margen_bruto_pct, flag_devu...	El margen no viene en las transacciones y es la base de A2 y A3.	Σ monto_devuelto concilia con devoluciones.csv; Σ margen_bruto = Σ monto_neto − Σ cost...
6	devoluciones	Variables derivadas	dias_a_devolucion, categoria, canal y segmento	Permite el análisis de patrones de devolución sin repetir joins (A3).	R22/R23: devoluciones totales y dentro del plazo de 30 días.
7	interacciones_crm	Felicitaciones con estado de resolución (233)	resolucion = "no_aplica"	Una felicitación no es un caso a resolver; evita inflar las quejas no resueltas en A3.	assert: todas las felicitaciones quedan como no_aplica.
8	interacciones_crm	tiempo_respuesta > 168 h (15)	Conservar; flag_respuesta_extrema y tiempo_respuesta_wins (winsorizado al p99)	Son señal válida de mal servicio; la winsorización protege los promedios.	p99 = 109.3 h; el valor original se conserva.
9	campanas_marketing	convertido = 1 sin compra en ≤30 días (618)	Conservar el flag oficial; crear flag_conversion_verificada y monto_compra_30d	Permite calcular el retorno con compras reales y probar la robustez de las conclusione...	R19 persiste a propósito (§6.1): es limitación del dato, no se maquilla.
10	campanas_marketing	Doble envío del mismo tipo y fecha (2 filas; cliente CLI01899)	Conservar ambos; flag_envio_duplicado	Descuento y resultado distintos: no es un duplicado técnico.	PK única y 0 filas idénticas (§2).
11	todas	Registros con valores extremos o inconsistentes	Marcar, nunca borrar	Un registro eliminado no se puede auditar; el flag deja la decisión en manos de cada a...	Validaciones de la §7: claves únicas, integridad referencial y reconciliación de montos.

Por último se exportan las tablas limpias para el posterior análisis.

Modelo Dimensional

[Enlace a LucidChart]



A2 - Análisis de Rentabilidad y Comportamiento de Compra

En este apartado se analiza de dónde viene el margen de RetailVenture y qué lo erosiona. Se responden las cuatro preguntas del enunciado: qué segmentos, categorías y canales aportan más y menos al margen bruto; cuál es el Customer Lifetime Value (CLV) por segmento y si algún segmento está en declive; si existe estacionalidad en las ventas; y si los descuentos generan volumen suficiente para compensar el margen que sacrifican. Se trabajó con las tablas limpias de data/clean generadas en A1, en el notebook 02_rentabilidad.ipynb.

Antes de calcular se definieron tres medidas de margen, todas en USD:

- **Margen bruto:** monto neto menos costo total. Es el margen después del descuento y antes de las devoluciones.
- **Margen neto (escenario base):** margen bruto menos el monto devuelto más el costo recuperado. Se asume que el producto devuelto vuelve al inventario, salvo que el motivo sea *producto defectuoso* o *fraude*.
- **Margen neto pesimista:** margen bruto menos el monto devuelto, sin recuperar ningún producto. Se usa como análisis de sensibilidad.

Se trabaja con el margen neto y no solo con las ventas porque un cliente o una categoría que vende mucho pero devuelve mucho no es necesariamente rentable.

Contribución al margen por segmento, categoría y canal

Para cada dimensión se calcularon las ventas, el margen bruto y el margen neto, su participación sobre el total, el margen porcentual, el descuento promedio y la tasa de devolución. En las tablas, mb_% y mn_% son el margen bruto y neto como porcentaje de las ventas.

Segmento · contribución al margen

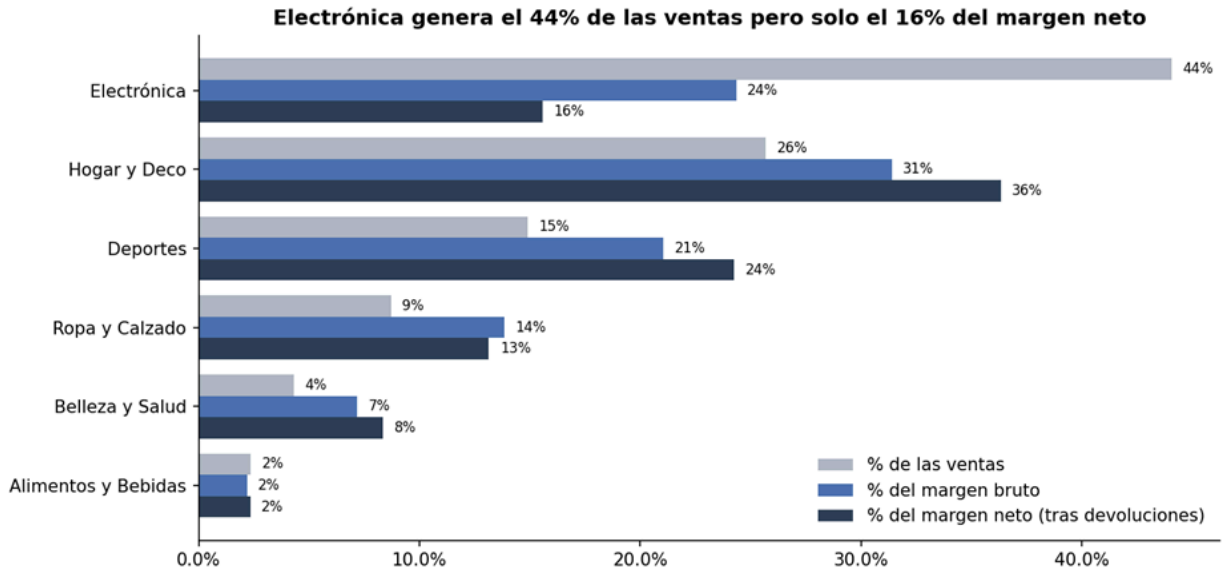
	ventas	margen_neto	%_ventas	%_margen_bruto	%_margen_neto	mb_%	mn_%	desc_prom	tasa_dev
Frecuente	8,766,759	1,530,616	50.4	49.5	49.0	24.3	17.5	5.6	13.5
Premium	5,280,661	995,062	30.4	31.2	31.9	25.5	18.8	4.2	13.4
Esporádico	2,701,502	482,895	15.5	15.6	15.5	25.0	17.9	5.7	13.7
Nuevo	326,779	65,456	1.9	1.9	2.1	24.7	20.0	5.5	12.1
Inactivo	317,287	49,202	1.8	1.8	1.6	24.5	15.5	5.8	12.6

Los segmentos Frecuente (49,5 % del margen bruto) y Premium (31,2 %) concentran el **81 % del margen**, mientras que Nuevo e Inactivo aportan menos del 2 % cada uno. El margen porcentual es casi igual en todos los segmentos (entre 24,3 % y 25,5 %), por lo que los segmentos se diferencian por **volumen y recurrencia de compra**, no por rentabilidad unitaria. Premium tiene el mejor margen bruto porque recibe el menor descuento promedio (4,2 % frente a ~5,6 %).

Categoría · contribución al margen

	ventas	margen_neto	%_ventas	%_margen_bruto	%_margen_neto	mb_%	mn_%	desc_prom	tasa_dev
Hogar_y_Deco	4,465,865	1,134,557	25.7	31.4	36.3	30.3	25.4	5.1	9.8
Electrónica	7,662,506	486,468	44.1	24.3	15.6	13.7	6.3	5.3	17.7
Deportes	2,592,709	757,171	14.9	21.0	24.2	35.0	29.2	5.4	10.7
Ropa_y_Calzado	1,513,397	410,523	8.7	13.9	13.1	39.4	27.1	5.1	21.8
Belleza_y_Salud	748,632	261,085	4.3	7.2	8.4	41.3	34.9	5.2	10.6
Alimentos_y_Bebidas	409,879	73,425	2.4	2.2	2.4	23.0	17.9	5.1	10.2

En las categorías está la mayor asimetría. **Hogar y Deco** es el mayor contribuyente: aporta el 31 % del margen bruto y el **36 % del margen neto** con solo el 26 % de las ventas. **Electrónica**, en cambio, es el 44 % de las ventas pero apenas el 24 % del margen bruto y el **16 % del margen neto**: tiene el margen más bajo (13,7 % bruto y 6,3 % neto) y una de las tasas de devolución más altas (17,7 %). Belleza y Salud tiene el mejor margen (41 % bruto y 35 % neto), pero pesa solo el 4 % de las ventas, por lo que representa una oportunidad de crecimiento. Ropa y Calzado tiene buen margen bruto (39 %), pero su tasa de devolución, la más alta (21,8 %), le resta 12 puntos de margen.



La gráfica compara, para cada categoría, su peso en las ventas, en el margen bruto y en el margen neto. Electrónica es la única categoría que pesa mucho más en ventas que en margen; Hogar y Deco, Deportes y Belleza y Salud generan en conjunto el 69 % del margen neto con el 45 % de las ventas.

Canal · contribución al margen

	ventas	margen_neto	%_ventas	%_margen_bruto	%_margen_neto	mb_%	mn_%	desc_prom	tasa_dev
tienda_fisica	7,862,504	1,503,792	45.2	47.5	48.1	26.0	19.1	3.7	13.2
online	6,547,309	1,066,957	37.6	34.6	34.2	22.8	16.3	7.5	13.8
app_movil	2,983,174	552,481	17.2	17.9	17.7	25.9	18.5	3.7	13.3

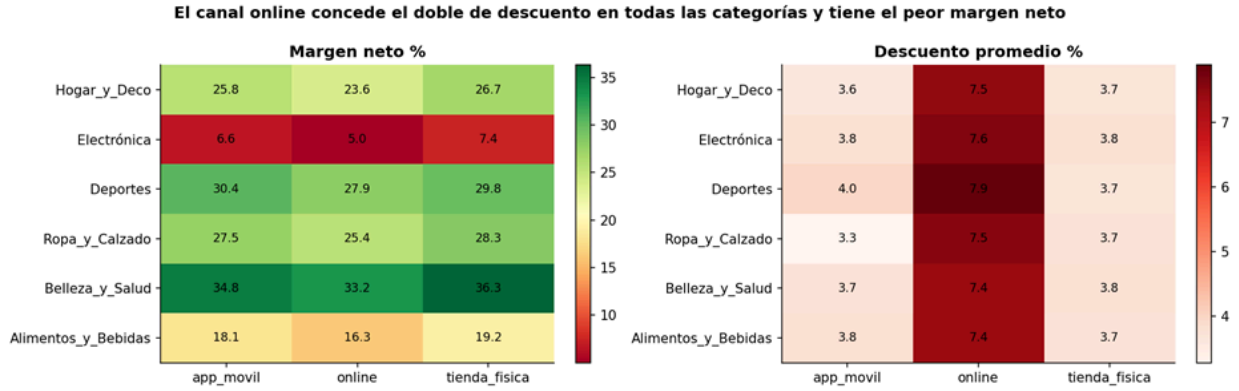
La tienda física aporta más margen del que vende (45 % de las ventas y 48 % del margen). El canal **online** es el menos rentable: concentra el 37,6 % de las ventas pero solo el 34,6 % del margen bruto, con un margen bruto de 22,8 % frente a 26,0 % de la tienda. La app móvil aporta poco en valor absoluto (17 % de las ventas), pero su margen porcentual (25,9 %) es similar al de la tienda, así que su menor contribución es de volumen y no de rentabilidad.

Para entender por qué el canal online es menos rentable, se comparó el margen a precio de lista con el margen real de cada canal:

Margen a precio de lista vs. margen real por canal

	margen_a_precio_lista_%	margen_real_%	descuento_%_ingreso	margen_sacrificado_USD
app_movil	28.78	25.91	3.87	$119,991
online	28.69	22.78	7.66	$543,000
tienda_fisica	28.78	26.02	3.73	$304,710

Los tres canales venden prácticamente la misma mezcla de productos (Electrónica representa ≈ 44 % en todos) y su margen a precio de lista es idéntico (28,7–28,8 %). **Toda la brecha se explica por el descuento**: el canal online concede un 7,7 % sobre el precio de lista, frente a 3,7–3,9 % en la tienda y la app. Esto equivale a $543.000 en 24 meses, el 56 % de todos los descuentos de la empresa. Si el canal online aplicara el mismo descuento que la tienda y el volumen no reaccionara (lo que se comprueba en la sección de descuentos), el margen bruto aumentaría en ≈ $139.000 por año.



El mapa de la izquierda muestra el margen neto porcentual de cada combinación de categoría y canal, y el de la derecha el descuento promedio. Electrónica es la de menor margen en los tres canales, y en todas las categorías el canal online tiene el menor margen y el mayor descuento, lo que confirma que el problema del canal es el descuento y no los productos que vende.

Como el margen neto depende del supuesto sobre la recuperación del producto devuelto, se calculó la sensibilidad para Electrónica:

Sensibilidad del margen neto de Electrónica al supuesto de recuperación

	margen_neto_USD	margen_neto_%
Pesimista (no se recupera nada)	$-348,916	-4.6%
Base (se recupera salvo defecto/fraude)	$486,468	6.3%
Optimista (se recupera todo)	$860,550	11.2%

Según cuánto producto devuelto se recupere, el margen neto de Electrónica va de −4,6 % a +11,2 %. En los tres escenarios sigue siendo la categoría menos rentable y queda muy por debajo del promedio de la empresa (18 %), así que **la conclusión no depende del supuesto**. Además, el 27,5 % de sus devoluciones son por producto defectuoso, que no se puede revender.

También se revisaron otros cortes de cliente: ciudad, rango de edad y canal de adquisición. En todos ellos el margen bruto va de 23,8 % a 25,7 % y la tasa de devolución de 12,4 % a 14,3 %, y la participación de cada grupo en el margen es igual a su participación en las ventas. Es decir, **la rentabilidad depende de qué se vende (categoría) y**

de cómo se vende (canal y descuento), no de quién compra.

Customer Lifetime Value (CLV) por segmento

El CLV se estimó con un modelo histórico-predictivo con retención, expresado en margen neto y descontado a valor presente:

$$CLV = m \times \Sigma\, [\, r / (1 + i)\,]^t\,, \quad con\ t = 0, 1, \ldots, H - 1$$

- **m:** margen neto anual promedio por cliente activo del segmento en 2024 (frecuencia anual × margen neto por compra).
- **r:** tasa de retención anual, es decir, la proporción de clientes activos en 2023 que vuelven a comprar en 2024.
- **i:** tasa de descuento del 12 % anual en USD, como costo de capital de referencia.
- **H:** horizonte de 3 años. Con solo 24 meses de historia no es defendible proyectar más allá, y un horizonte finito evita que un segmento con retención cercana a 100 % tenga un CLV casi infinito.

Al multiplicar el CLV por los clientes registrados de cada segmento se obtiene el valor de la cartera, que mide el valor potencial de cada segmento.

CLV a 3 años por segmento

	clientes_activos	frecuencia_anual	ticket	margen_anual_cliente	retencion	CLV_3a	var_CLV_%	%_valor_cartera
Premium	805	9.37	$351	$621	100.0%	$1,670	+0.9%	32.0%
Frecuente	2,405	5.33	$340	$314	99.3%	$840	-2.2%	48.5%
Esporádico	2,281	1.71	$346	$109	77.7%	$236	+4.3%	15.9%
Nuevo	438	1.15	$344	$80	32.0%	$109	+7.7%	2.1%
Inactivo	435	1.00	$345	$53	0.0%	$53	-11.0%	1.4%

Premium tiene el mayor CLV (**$1.670**) por su frecuencia de 9,4 compras al año y una retención del 100 %, seguido de Frecuente (**$840**), con 5,3 compras al año y 99 % de retención. Esporádico (236), $Nuevo$(109) e Inactivo ($53) valen mucho menos: en Nuevo solo el 32 % vuelve a comprar al año siguiente. El **ticket promedio es igual en todos los segmentos (~$345)**, así que el valor de un cliente lo determinan su frecuencia y su retención, no cuánto gasta en cada compra. **Premium y Frecuente suman el 80,5 % del valor de la cartera** con el 40 % de los clientes.

segmento	i=8%, H=2	i=8%, H=3	i=8%, H=5	i=12%, H=2	i=12%, H=3	i=12%, H=5	i=20%, H=2	i=20%, H=3	i=20%, H=5
Premium	1196.0	1728.0	2678.0	1175.0	1670.0	2507.0	1138.0	1570.0	2228.0
Frecuente	604.0	869.0	1338.0	593.0	840.0	1254.0	575.0	790.0	1116.0
Esporádico	187.0	243.0	313.0	184.0	236.0	298.0	179.0	225.0	273.0
Nuevo	104.0	111.0	114.0	103.0	109.0	112.0	101.0	107.0	109.0
Inactivo	53.0	53.0	53.0	53.0	53.0	53.0	53.0	53.0	53.0

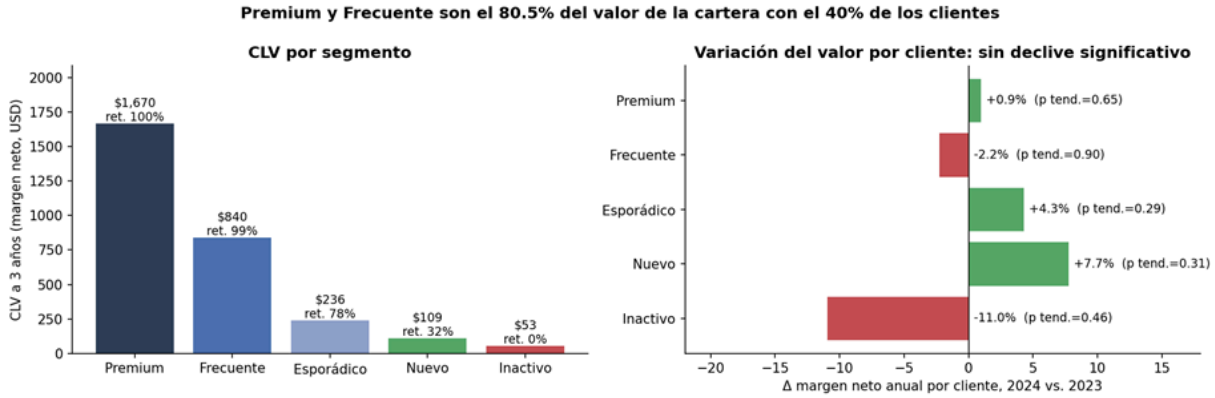
La tabla de sensibilidad recalcula el CLV con tasas de descuento de 8 %, 12 % y 20 % y horizontes de 2, 3 y 5 años. Los valores cambian, pero **el ranking de los segmentos es el mismo en los nueve escenarios**, por lo que las

conclusiones no dependen de los parámetros elegidos.

Pareto del margen neto por cliente

	resultado
Concentración: el 20% de clientes con más margen	63.3%
Clientes con margen neto acumulado negativo	508
Proporción de la cartera con margen negativo	6.7%
Margen neto que restan esos clientes	$215,869

El valor está muy concentrado: el 20 % de clientes con más margen genera el 63 % del margen neto, y el 96 % de ese grupo pertenece a Premium o Frecuente. También se identificaron 508 clientes (6,7 % de la cartera) con margen neto acumulado negativo, que restan $216.000 por devolver productos de bajo margen. Este grupo se analiza en A3, donde se verifica que no se trata de devolvedores seriales.



La gráfica de la izquierda muestra el CLV de cada segmento junto a su retención; la de la derecha, la variación del margen neto anual por cliente entre 2023 y 2024. Ninguna variación es estadísticamente significativa.

¿Qué segmentos están en declive?

No basta con mirar las ventas totales: un segmento puede mantenerlas porque gana clientes mientras cada cliente vale menos. Por eso se descompuso la variación entre 2023 y 2024 en clientes activos, frecuencia de compra y margen por compra, y se probó con una regresión OLS sobre los 24 meses si la tendencia mensual del margen de cada segmento es distinta de cero.

Variación 2024 vs. 2023 por segmento

	Δ clientes %	Δ frecuencia %	Δ ticket %	Δ margen/compra %	Δ margen/cliente %	p tendencia
Premium	+0.0	+2.5	-1.9	-1.5	+0.9	0.66
Frecuente	-0.1	+1.6	-2.3	-3.7	-2.2	0.90
Esporádico	+1.2	-0.8	-0.6	+5.2	+4.3	0.29
Nuevo	+7.1	+2.8	+2.5	+4.9	+7.7	0.31
Inactivo	-2.5	+0.0	-8.0	-11.0	-11.0	0.46

Ningún segmento muestra una tendencia estadísticamente significativa (todos los p ≥ 0,29), así que no hay un colapso. Sí hay señales que conviene vigilar:

- **Inactivo:** el margen anual por cliente cae 11 % y el ticket 8 %, el único segmento con una caída como la que cita el caso. Sin embargo, pesa solo el 1,4 % del valor de la cartera.
- **Frecuente:** el margen por compra cae 3,7 % y el margen por cliente 2,2 %. Es poco en porcentaje, pero sobre el 48 % del valor de la cartera equivale a ≈ $17.000 menos de margen por año.

trim_desde_alta	0	1	2	3	4	5	6	7
cohorte								
2023Q1	100.0	62.6	61.0	60.0	61.1	60.8	60.8	61.0
2023Q2	100.0	42.7	42.7	43.7	43.5	41.6	45.8	NaN
2023Q3	100.0	30.6	31.4	30.3	31.7	31.4	NaN	NaN
2023Q4	100.0	22.5	24.5	22.9	23.7	NaN	NaN	NaN
2024Q1	100.0	23.0	22.3	22.3	NaN	NaN	NaN	NaN
2024Q2	100.0	17.1	18.3	NaN	NaN	NaN	NaN	NaN
2024Q3	100.0	15.1	NaN	NaN	NaN	NaN	NaN	NaN
2024Q4	100.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN

La tabla de cohortes muestra qué porcentaje de los clientes que compraron por primera vez en cada trimestre sigue comprando en los trimestres siguientes. La recompra al trimestre siguiente cae de 30,6 % (2023-T3) a 15,1 % (2024-T3). Como las primeras cohortes de 2023 incluyen clientes que ya existían antes del período analizado, la comparación válida es entre las cohortes de 2024 (23,0 % → 17,1 % → 15,1 %): **la tendencia a la baja se mantiene**. Además, el 47,6 % de los clientes Esporádicos lleva más de 180 días sin comprar, lo que lo convierte en el segmento de mayor valor en riesgo que se analiza en A3.

En conclusión, el valor de RetailVenture está **concentrado y es estable** en Premium y Frecuente; el deterioro está

en la incorporación y retención de clientes nuevos y en la leve erosión del ticket de Frecuente.

Estacionalidad: picos, valles y tendencias

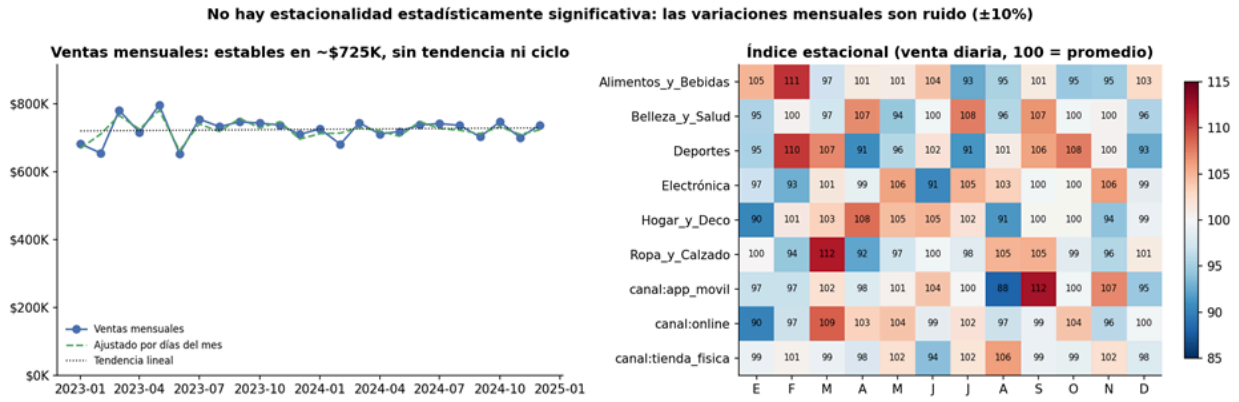
Como los meses no tienen la misma cantidad de días, los índices estacionales se calcularon sobre la **venta promedio diaria** de cada mes. Que un mes quede por encima del promedio no basta para hablar de estacionalidad, por lo que se aplicaron tres pruebas:

1. **Kruskal-Wallis:** compara la distribución de la venta diaria entre meses. Se aplicó la corrección de Bonferroni porque se hicieron 10 pruebas (total, 6 categorías y 3 canales), lo que fija el umbral de significancia en 0,005.
2. **Repetibilidad:** si la estacionalidad fuera real, el patrón mensual de 2023 se repetiría en 2024, así que se calculó la correlación entre los índices de los dos años.
3. **Tendencia:** pendiente de una regresión OLS sobre las ventas mensuales.

Pruebas de estacionalidad (venta diaria por mes)

	mes_pico	indice_pico	mes_valle	indice_valle	kruskal_p	corr_patron_2023_2024	tendencia_p
TOTAL	3	103.4	1	95.5	0.63	-0.44	0.71
Alimentos_y_Bebidas	2	110.7	7	92.6	0.21	-0.01	0.83
Belleza_y_Salud	7	107.6	5	94.4	0.52	-0.32	0.30
Deportes	2	110.4	4	90.8	0.05	0.33	0.87
Electrónica	11	106.2	6	90.6	0.54	-0.06	0.90
Hogar_y_Deco	4	108.3	1	90.4	0.27	0.10	0.77
Ropa_y_Calzado	3	111.9	4	92.3	0.42	-0.18	0.41
canal:app_movil	9	112.4	8	88.0	0.58	0.18	0.97
canal:online	3	108.8	1	90.2	0.39	0.12	0.89
canal:tienda_fisica	8	106.2	6	93.9	0.72	-0.38	0.61

No hay estacionalidad estadísticamente significativa en el total, en ninguna categoría ni en ningún canal. El valor p de Kruskal-Wallis es 0,63 en el total, y el único menor a 0,05 (Deportes, 0,046) deja de ser significativo con la corrección de Bonferroni. El patrón tampoco se repite: la correlación entre los índices de 2023 y 2024 es −0,44 en el total. Y no hay tendencia: la pendiente es de +0,05 % mensual (p = 0,71).



La gráfica muestra las ventas mensuales y los índices estacionales por categoría. Las ventas son estables en ~$725.000 por mes, con un coeficiente de variación de 3 % en transacciones y de 3,7 % en ticket. El aparente valle de febrero (−8 %) desaparece al ajustar por los días del mes (índice diario de 98,5): es un efecto de calendario, no de demanda. El día de la semana tampoco influye (p = 0,99).

Esto tiene tres implicaciones de negocio. Primero, la presión sobre los márgenes es **estructural, no cíclica**: no se explica por una temporada baja ni se va a corregir sola. Segundo, no hay picos de demanda que justifiquen descuentos de temporada, y de hecho los descuentos están repartidos de forma pareja durante el año. Tercero, el inventario y el personal se pueden planificar con una demanda plana. Cabe aclarar que el dataset es sintético y no reproduce ciclos típicos del retail venezolano, como diciembre o el regreso a clases.

Conclusiones de A2

- **El problema de rentabilidad está en la mezcla de productos y en los descuentos, no en los clientes.** Electrónica es el 44 % de las ventas pero solo el 16 % del margen neto, mientras Hogar y Deco, Deportes y Belleza y Salud generan el 69 % del margen neto con el 45 % de las ventas.
- **El canal online pierde 3,2 puntos de margen porque descuenta el doble** que la tienda (7,7 % frente a 3,7 %), con la misma mezcla de productos.
- **Los descuentos no generan volumen** (+0,2 %, no significativo en cuatro pruebas distintas). Costaron $968.000, el 22,5 % del margen bruto, y por encima del 20 % Electrónica vende a pérdida.
- **Premium y Frecuente concentran el 80,5 % del valor de la cartera** y no están en declive. Las señales de alerta son la caída de la recompra de los clientes nuevos y la leve erosión del margen de Frecuente.
- **No hay estacionalidad ni tendencia:** las ventas son planas en ~$725.000 por mes, por lo que la caída de márgenes es estructural y no se corregirá sola.

A3 - Detección de Fugas de Ingresos

En este apartado se analiza cuatro posibles fuentes de pérdida, que son las devoluciones, contactos con el CRM, clientes que dejan de comprar y dinero cedido mediante descuentos. Usa las ventas, clientes, devoluciones e interacciones del CRM ya preparadas en data/clean.

Para el patrón de devoluciones, primero se calculó una tasa global de devolución y se compararon las tasas entre categorías, subcategorías, canales, segmentos y métodos de pago. Después, se exploró si las diferencias se concentraban en productos individuales o si eran un fenómeno general de ciertas categorías. También se revisó si la tasa había cambiado entre trimestres.

Para el patrón de devoluciones realizamos pruebas de a χ^2 de independencia para evaluar si la proporción de transacciones devueltas está relacionada con cada dimensión. Se realiza regresión logística para comparar la asociación de categoría, segmento, canal y descuento con la devolución. Además de pruebas binomiales por producto para contrastar cada producto contra la tasa global y contra la tasa de su propia categoría, y finalmente la estabilidad temporal, donde una χ^2 compara los trimestres y una regresión logística examina si existe una tendencia mensual.

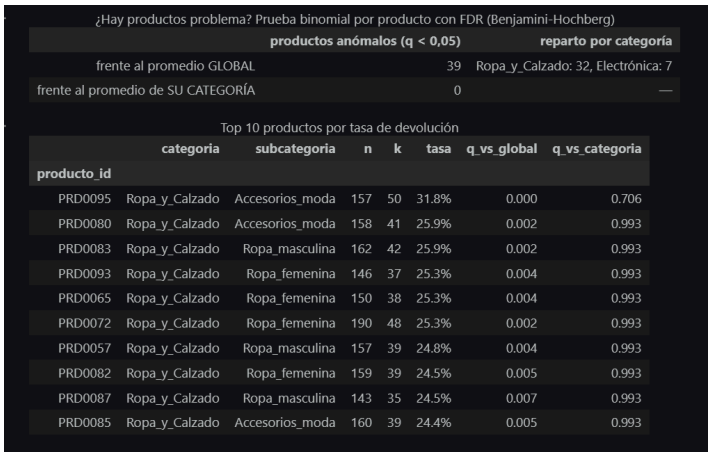
En la primera tabla de χ^2 cada fila evalúa si la tasa de devolución está asociada con una dimensión, categoría del producto, subcategoría, canal de venta, segmento del cliente, método de pago. La categoría y la subcategoría sí muestran asociación con las devoluciones, pues sus valores p son muy pequeños. En cambio, canal, segmento y método de pago tienen valores p mayores que 0,05.

En la segunda tabla se agrupa las transacciones por categoría. Se representan las columnas de transacciones, devoluciones, tasa, ventas, devuelto , margen_perdido y %_del_devuelto_total. Podemos ver en la tabla que Ropa y Calzado tiene la tasa más alta de devoluciones (21,8 %), mientras que Electrónica concentra el mayor monto devuelto y la mayor pérdida de margen. Por eso, una tasa alta y un impacto económico alto son dos cosas relacionadas, pero no idénticas.

dimensión	chi2	p_valor	V_Cramer	tasa_min	tasa_max
categoria	909.5	2.36e-194	0.135	9.8% (Hogar_y_Deco)	21.8% (Ropa_y_Calzado)
subcategoria	935.9	5.51e-183	0.137	8.8% (Decoración)	22.9% (Accesorios_moda)
canal	2.5	2.87e-01	0.007	13.2% (tienda_fisica)	13.8% (online)
segmento	2.6	6.34e-01	0.007	12.1% (Nuevo)	13.7% (Esporádico)
metodo_pago	0.8	9.42e-01	0.004	13.1% (transferencia)	13.6% (billetera_digital)

egoria	transacciones	devoluciones	tasa	ventas	devuelto	margen_perdido	%_del_devuelto_total
alzado	8311	1810	21.8%	$1,513,397	$320,972	$186,482	12.7%
trónica	8419	1486	17.7%	$7,662,506	$1,398,217	$562,833	55.2%
portes	8311	887	10.7%	$2,592,709	$271,615	$150,042	10.7%
_Salud	8287	878	10.6%	$748,632	$79,805	$48,417	3.1%
ebidas	8317	845	10.2%	$409,879	$42,910	$20,843	1.7%
/_Deco	8355	818	9.8%	$4,465,865	$420,948	$218,481	16.6%

La primera tabla muestra las tasas observadas, muestra qué porcentaje de compras se devolvió en cada combinación. Por ejemplo, el 21,5 % de las compras de clientes Premium en Ropa y Calzado se devolvió. El patrón principal es que las tasas son más altas en Ropa y Calzado y Electrónica, sin importar mucho el segmento.; la segunda compara las odds de devolución entre categorías, segmentos, canales y descuentos, considerando esas variables al mismo tiempo, confirma que, al considerar varios factores juntos, la categoría del producto es la diferencia más clara.



¿Hay productos problema? Prueba binomial por producto con FDR (Benjamini-Hochberg)

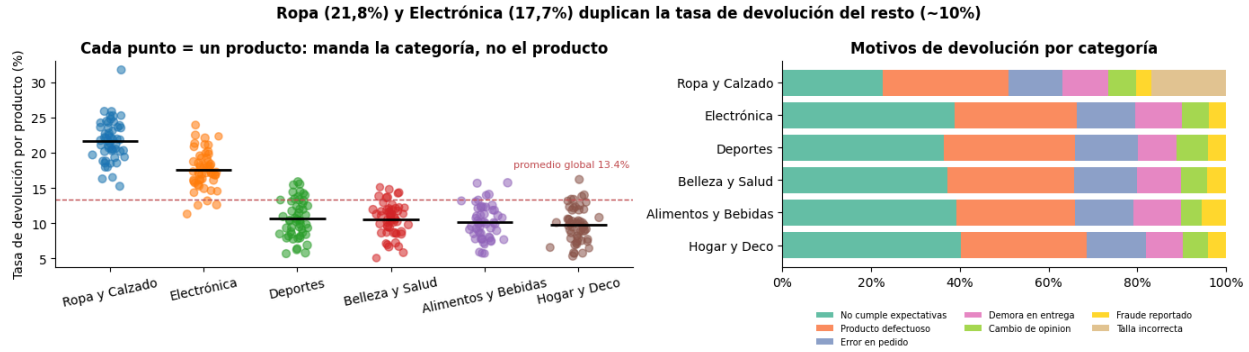
	productos anómalos (q < 0,05)	reparto por categoría
frente al promedio GLOBAL	39	Ropa_y_Calzado: 32, Electrónica: 7
frente al promedio de SU CATEGORÍA	0	—

Top 10 productos por tasa de devolución

producto_id	categoria	subcategoria	n	k	tasa	q_vs_global	q_vs_categoria
PRD0095	Ropa_y_Calzado	Accesorios_moda	157	50	31.8%	0.000	0.706
PRD0080	Ropa_y_Calzado	Accesorios_moda	158	41	25.9%	0.002	0.993
PRD0083	Ropa_y_Calzado	Ropa_masculina	162	42	25.9%	0.002	0.993
PRD0093	Ropa_y_Calzado	Ropa_femenina	146	37	25.3%	0.004	0.993
PRD0065	Ropa_y_Calzado	Ropa_femenina	150	38	25.3%	0.004	0.993
PRD0072	Ropa_y_Calzado	Ropa_femenina	190	48	25.3%	0.002	0.993
PRD0057	Ropa_y_Calzado	Ropa_masculina	157	39	24.8%	0.004	0.993
PRD0082	Ropa_y_Calzado	Ropa_femenina	159	39	24.5%	0.005	0.993
PRD0087	Ropa_y_Calzado	Ropa_masculina	143	35	24.5%	0.007	0.993
PRD0085	Ropa_y_Calzado	Accesorios_moda	160	39	24.4%	0.005	0.993

La tabla revisa si algunos productos tienen una tasa de devolución inusualmente alta. Frente al promedio global: 39 productos superan significativamente el promedio general; 32 son de Ropa y Calzado y 7 de Electrónica. Frente al promedio de su categoría: no hay productos anómalos. Es decir, aunque esos productos devuelven más que el promedio general, su tasa no es excepcional comparada con otros productos de la misma categoría.

- En la tabla inferior, n es el número de transacciones y k el número de devoluciones.
- q_vs_global y q_vs_categoria son valores ajustados por comparar muchos productos; un valor menor que 0,05 indica una diferencia significativa.



Tasa de devolución por trimestre (%) con su IC95

fecha	mean	IC95
2023Q1	13.22	0.85
2023Q2	13.65	0.85
2023Q3	12.97	0.84
2023Q4	13.84	0.85
2024Q1	13.31	0.84
2024Q2	13.32	0.84
2024Q3	13.81	0.86
2024Q4	13.45	0.84

¿La tasa de devolución está aumentando?

	resultado
χ^2 de homogeneidad entre trimestres (p)	0.846
OR por mes de la tendencia	1.0007
p-valor de la tendencia	0.727

La tasa global fue aproximadamente 13,4 %. La categoría fue la dimensión con asociación más clara con las devoluciones: Ropa y Calzado registró 21,8 % y Electrónica 17,7 %, frente a cerca de 10 % en las demás categorías. La asociación por categoría fue estadísticamente significativa (χ^2, $p \approx 10^{-194}$; V de Cramér = 0,14). Canal, segmento y método de pago no mostraron asociaciones significativas en las pruebas reportadas.

La regresión logística refuerza ese patrón: frente a Alimentos y Bebidas, las odds de devolución fueron aproximadamente 2,5 veces mayores en Ropa y Calzado y 1,9 veces mayores en Electrónica. El descuento no fue significativo en ese modelo.

La tasa se mantuvo entre 13,0 % y 13,8 % durante los ocho trimestres; la prueba de homogeneidad dio p = 0,85 y la tendencia mensual p = 0,73. Por lo tanto, el nivel cercano al 14 % es alto, pero el análisis no detecta un aumento reciente.

Para la devolución repetitiva de clientes, pretendemos comparar cada cliente con lo esperable dado su número de compras y las categorías que compró. Se utilizarán las pruebas: Prueba binomial por cliente que calcula si el número de devoluciones del cliente sería inusual bajo la tasa esperada para sus compras, se aplica FDR para tener en cuenta que se prueban muchos clientes y se simulan 500 escenarios donde cada transacción tiene la tasa de devolución propia de su categoría donde se compara la cantidad de clientes con múltiples devoluciones observada con la que aparece por azar.

¿Devolvedores seriales? Prueba binomial por cliente con FDR

	resultado
Clientes con al menos una devolución	3,679
Proporción de la cartera	48.4%
Clientes con devoluciones anómalas (FDR q < 0,05)	0
Clientes con p < 0,01 sin corregir	14
Los que se esperarían por azar	~76

	umbral	observado	esperado_por_azar	IC95_azar
0	≥2 devoluciones	1711	1709.506	1654–1764
1	≥3 devoluciones	793	785.666	743–834
2	≥4 devoluciones	348	327.054	297–356
3	≥5 devoluciones	120	123.276	104–143
4	≥6 devoluciones	44	42.472	30–55
5	≥7 devoluciones	20	13.542	7–21
6	≥8 devoluciones	7	3.924	1–8

Fraude y concentración del monto devuelto

	resultado
Devoluciones por fraude	272 ($86,410)
Clientes implicados	265
Clientes con más de un fraude	5
Fraude como % de las devoluciones del canal	app_movil: 4.2% · online: 3.5% · tienda_fisica: 4.5%
Concentración: el 5% de clientes con más monto devuelto	40.9%
Correlación monto devuelto vs. monto comprado	r = 0.55

El 48 % de los clientes tuvo al menos una devolución, pero ninguno resultó anómalo después de corregir por comparaciones múltiples. Sin esa corrección, 14 clientes tuvieron p < 0,01, frente a unos 76 que se esperarían por azar al hacer tantas pruebas.

La simulación también encontró resultados cercanos a lo esperado. Por ejemplo, hubo 793 clientes con tres o más devoluciones, frente a unos 786 esperados; el intervalo simulado del 95 % fue 743–834. En los umbrales extremos de siete u ocho devoluciones hay un pequeño exceso, pero el notebook lo considera de impacto económico reducido.

El 5 % de clientes con mayor monto devuelto concentra el 41 % de ese monto, pero el monto comprado y el devuelto están correlacionados (r = 0,55): los clientes que más compran también tienen más ocasiones de devolver. Se encontraron 272 casos de fraude reportado, repartidos en 265 clientes; solo cinco repitieron. El análisis no encontró evidencia de un grupo de “devolvedores seriales” que justifique penalizar clientes por el número bruto de devoluciones.

Luego tenemos el contacto con el CRM y compras posteriores que pretende estudiar si las quejas no resueltas se asocian con menos compras posteriores y si resolverlas cambia el resultado.

grupo	clientes	compras_pre	compras_post	delta_compras	gasto_pre	gasto_post	sin_compra_post	delta_gasto_%
control_sin_CRM	5332	1.61	1.66	+0.05	$551	$585	34.9%	+6.1%
contacto_consulta	397	1.51	1.43	-0.08	$480	$435	38.8%	-9.3%
acto_soporte_tecnico	242	1.46	1.51	+0.05	$537	$522	40.1%	-2.7%
queja_resuelto	272	1.44	1.40	-0.05	$479	$425	40.4%	-11.2%
arcialmente_resuelto	117	1.44	1.36	-0.09	$496	$513	39.3%	+3.5%
queja_escalado	150	1.81	1.73	-0.07	$644	$593	36.0%	-8.0%
queja_sin_resolver	176	1.66	1.48	-0.19	$627	$464	42.6%	-26.0%

La primera tabla compara las compras y el gasto promedio 180 días antes y después del primer contacto con CRM. El grupo sin contacto aumentó levemente sus compras (+0,05), mientras que quienes tuvieron una queja sin resolver bajaron más (−0,19 compras; gasto −26 %). Son cambios descriptivos, por sí solos no demuestran que el contacto o la queja causaron la disminución.

Efecto sobre COMPRAS en los 180 días posteriores (vs. control, ajustado por compras previas y segmento)

	efecto	IC95_inf	IC95_sup	p_valor
contacto_consulta	-0.062	-0.175	+0.051	0.284
contacto_soporte_tecnico	+0.005	-0.137	+0.146	0.950
queja_escalado	+0.066	-0.156	+0.289	0.558
queja_parcialmente_resuelto	-0.105	-0.305	+0.095	0.304
queja_resuelto	-0.086	-0.228	+0.057	0.238
queja_sin_resolver	-0.087	-0.267	+0.092	0.342

Efecto sobre GASTO (USD) en los 180 días posteriores

	efecto	IC95_inf	IC95_sup	p_valor
contacto_consulta	-90.9	-157.2	-24.7	0.000
contacto_soporte_tecnico	-9.6	-113.4	+94.2	0.900
queja_escalado	+2.5	-121.9	+127.0	1.000
queja_parcialmente_resuelto	-1.1	-124.0	+121.8	1.000
queja_resuelto	-97.0	-177.4	-16.5	0.000
queja_sin_resolver	-93.7	-198.6	+11.2	0.100

Contrastes del §2: ¿es la queja, el contacto o la resolución?

	resultado
Cualquier queja vs. control · gasto 180 d	-59.3 USD (-10.1%)
p-valor (queja → gasto)	0.035
Cualquier queja vs. control · compras	-0.057
p-valor (queja → compras)	0.237
Cualquier contacto vs. control · gasto 180 d	-59.8 USD (-10.2%)
p-valor (contacto → gasto)	0.006
Sin resolver vs. resuelto · compras	+0.002
p-valor (resolución → compras)	0.986
Gasto medio del control en los 180 d	$585

Odds ratio de NO volver a comprar en 180 días (vs. control sin CRM)

	odds_ratio	p_valor
contacto_consulta	0.99	0.940
contacto_soporte_tecnico	1.16	0.373
queja_escalado	1.03	0.897
queja_parcialmente_resuelto	1.14	0.561
queja_resuelto	1.13	0.427
queja_sin_resolver	1.35	0.140

La tabla compara las compras y el gasto durante los 180 días posteriores a una queja o contacto con CRM. El gasto baja cerca de $59 tanto en clientes con quejas como en quienes hicieron consultas, pero la cantidad de compras y la probabilidad de no volver no cambian significativamente; por eso, la caída se asocia al contacto, no específicamente a quejas sin resolver.

Robustez · ventana de 90 días: efecto sobre compras vs. control

	efecto	IC95_inf	IC95_sup	p_valor
contacto_consulta	-0.016	-0.094	+0.062	0.692
contacto_soporte_tecnico	-0.019	-0.118	+0.081	0.712
queja_escalado	-0.017	-0.144	+0.109	0.786
queja_parcialmente_resuelto	-0.096	-0.224	+0.031	0.139
queja_resuelto	-0.062	-0.146	+0.022	0.145
queja_sin_resolver	-0.082	-0.186	+0.022	0.123

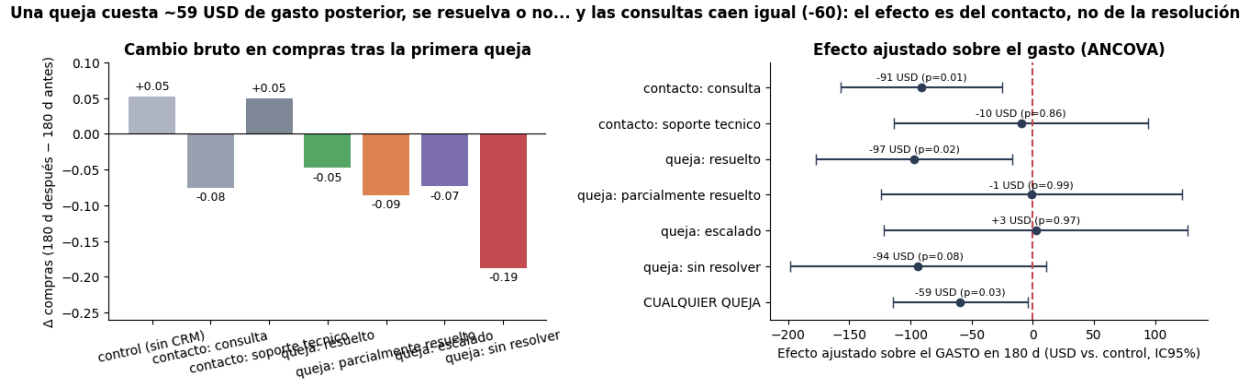
Tiempo de respuesta y compra posterior (solo quejas, por cuartil)

t_resp	n	delta_compras	sin_compra_post
Q1 ≤6h	179	-0.101	41.3%
Q2 6–11h	179	+0.061	35.8%
Q3 11–21h	179	-0.045	41.9%
Q4 >21h	178	-0.292	40.4%

¿La velocidad de respuesta cambia la compra posterior?

	resultado
Compras por cada 24 h adicionales de respuesta	-0.042
p-valor	0.471

La tabla muestra que, al analizar una ventana de 90 días, no se detecta un cambio significativo en las compras tras las quejas o consultas: todos los valores p son mayores que 0,05 y los intervalos incluyen cero. Aunque las compras parecen bajar cuando la respuesta tarda más de 21 horas, la prueba estadística tampoco confirma esa relación (p = 0,471).



La gráfica compara compras y gasto antes y después del contacto con la empresa. En promedio, las compras disminuyen más en el grupo con quejas sin resolver, pero, al ajustar por diferencias previas, cualquier queja se asocia con unos $59 menos de gasto en seis meses. Las consultas también muestran una caída similar, así que el resultado apunta al contacto con el CRM, no necesariamente a la queja o a su resolución.

- Podemos destacar que en este apartado:
- No se encontró un efecto estadísticamente significativo de las quejas sobre el número de compras (p ≥ 0,24).
- Una queja se asoció con alrededor de $59 menos de gasto en 180 días que el grupo sin contacto (aproximadamente −10 %; IC95 %: −$114 a −$4; p = 0,035).

- El gasto no mejoró por el hecho de que la queja estuviera resuelta: el efecto estimado fue parecido para quejas resueltas y no resueltas (−$97 y −$94, respectivamente). La comparación de compras entre quejas resueltas y no resueltas tampoco mostró diferencia (p = 0,99).
- Los clientes que solo hicieron consultas también mostraron menor gasto: cerca de −$91, con IC95 % de −$157 a −$25.

En el análisis de riesgo de churn se compararon varias métricas para predecir qué clientes dejarían de comprar durante seis meses.

	AUC_backtest
Recencia (días)	0.696
Ratio de Inactividad (RI)	0.598
Probabilidad de la brecha (Poisson)	0.439
Frecuencia histórica (−compras)	0.817

	AUC de la recencia DENTRO de cada segmento
Esporádico	0.438
Frecuente	0.500
Nuevo	0.443
Premium	0.496

Test de razón de verosimilitud: recencia sobre frecuencia y segmento

	resultado
¿La recencia agrega información a la frecuencia? LR	2.20
p-valor (χ^2 con 1 gl)	0.138

La primera prueba muestra que la frecuencia histórica predice mejor el churn (AUC 0,817) y que la recencia no aporta información adicional significativa una vez considerada la frecuencia y el segmento (*p* = 0,138).

Intervalo entre compras (días) por segmento · CV ≈ 1 = proceso de Poisson

segmento	mean	std	CV
Premium	37.08	37.83	1.02
Frecuente	62.07	61.25	0.99
Esporádico	172.99	140.25	0.81
Nuevo	249.44	166.81	0.67

Compras promedio por cliente y semestre (ritmo estable = sin desgaste)

segmento \ sem	2023-S1	2023-S2	2024-S1	2024-S2
Premium	4.48	4.66	4.79	4.59
Frecuente	2.62	2.60	2.62	2.68
Esporádico	0.70	0.70	0.72	0.68
Nuevo	0.30	0.34	0.36	0.34
Inactivo	0.25	0.26	0.23	0.26

No-compra en 2024-S2: observado vs. esperado si cada cliente mantuviera su ritmo (pausa normal)

segmento	clientes	no_compra_observado	no_compra_esperado_sin_fuga	exceso_fuga_pp
Premium	805	1.2%	2.1%	-0.9
Frecuente	2421	6.8%	10.5%	-3.7
Esporádico	2652	49.0%	49.7%	-0.8
Nuevo	582	83.5%	66.7%	+16.8
Inactivo	652	100.0%	71.4%	+28.6

El CV cercano a 1 y las compras semestrales estables sugieren un ritmo compatible con Poisson; al comparar la no-compra observada con la esperada, el exceso de inactividad se concentra en Nuevos (+16,8 pp) e Inactivos (+28,6 pp), no en los segmentos de mayor valor.

Calibración del backtest · AUC fuera de tiempo de PI6 = 0.891

estado	clientes	PI6_predicho	no_compra_real
Activo	3,226	5.1%	5.4%
En riesgo	1,703	49.8%	40.7%
Alto riesgo	2,183	81.8%	79.9%

La tabla válida la métrica PI6: predice con buena precisión quién no comprará en seis meses (AUC = 0,891), especialmente en los grupos Activo y Alto riesgo; en “En riesgo” sobreestima algo la no compra.

Valor en riesgo a 6 meses por segmento (corte 2024-12-31)

segmento	clientes	en_riesgo	alto_riesgo	PI6_media	ingreso_en_riesgo_bruto_6m	fuga_estructural_6m	margen_fuga_estructural_6m	exceso_no_compra_pp	%_fuga_estructural
Premium	805	0	0	1.0%	$12,663	$0	$0	+0.0	0.0%
Frecuente	2,422	0	0	7.1%	$159,120	$0	$0	+0.0	0.0%
Esporádico	2,784	2,784	1,685	55.1%	$398,705	$0	$0	+0.0	0.0%
Nuevo	716	716	716	85.4%	$72,816	$13,769	$2,758	+16.8	37.7%
Inactivo	881	881	881	100.0%	$79,383	$22,710	$3,522	+28.6	62.3%
TOTAL	7,608	4,381	3,282	42.2%	$722,687	$36,480	$6,280	—	100.0%

La tabla muestra que el mayor riesgo de no comprar se concentra en los segmentos Nuevo e Inactivo: juntos representan toda la fuga estructural estimada, de aproximadamente $36.480 en ingresos y $6.280 en margen a seis meses. Los Esporádicos tienen más ingreso bruto expuesto, pero su inactividad se considera normal para su ritmo de compra.

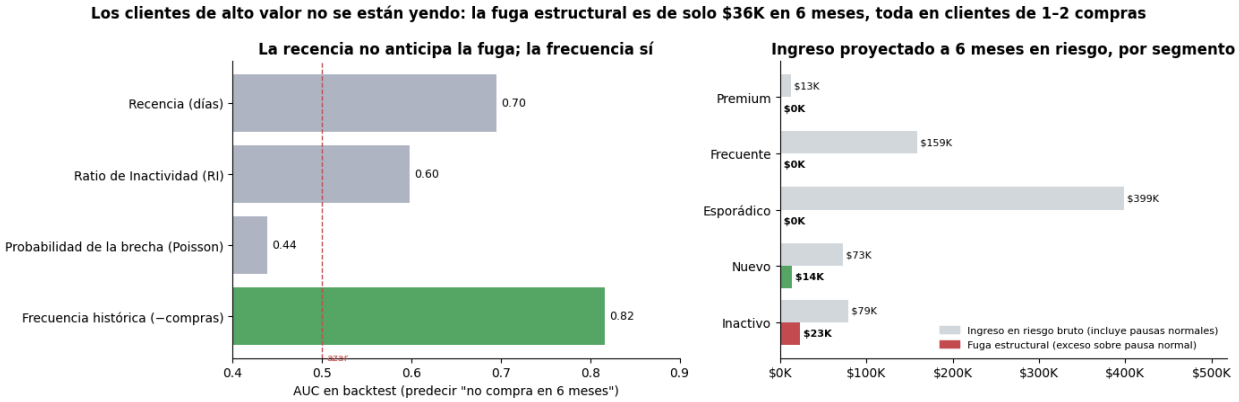
Flujo de clientes 2023 → 2024: ingreso que se va y que se repone

segmento	clientes_perdidos	ingreso_2023_perdidos	clientes_nuevos_2024	ingreso_2024_nuevos
Premium	0	0	0	0
Frecuente	17	34,020	15	32,736
Esporádico	503	332,676	530	418,163
Nuevo	278	107,525	307	119,922
Inactivo	446	167,257	435	150,030
TOTAL	1,244	641,478	1,287	720,851

Clientes con primera compra ≤ 2024-06 que no repiten

segmento	% que nunca hizo una segunda compra
Premium	0.0%
Frecuente	0.1%
Esporádico	9.3%
Nuevo	61.2%
Inactivo	100.0%

En 2024 se incorporaron más clientes e ingresos de los que se perdieron, pero el 61,2 % de los Nuevos no volvió a comprar, señalando un problema de recompra inicial. Muestra 4.381 clientes en riesgo o alto riesgo (2.784 Esporádicos, 716 Nuevos y 881 Inactivos). Ningún Premium ni Frecuente está en riesgo.



La frecuencia histórica predice mejor quién dejará de comprar; la fuga estructural estimada es de solo $36K en seis meses y se concentra en clientes Nuevos e Inactivos.

La métrica PI6 estima la probabilidad de inactividad a seis meses con alta precisión (AUC de 0,89) y un enfoque conservador. Aunque el segmento Esporádico concentra $399.000 en riesgo bruto, la fuga estructural real asciende a solo $36.000 en seis meses, focalizada principalmente en clientes Inactivos (62%) y Nuevos (38%). A pesar de que los ingresos entre 2023 y 2024 se mantuvieron estables por la adquisición de nuevos clientes, el negocio enfrenta una alta ineficiencia, ya que el 61% de los clientes Nuevos no realiza una segunda compra. En consecuencia, el churn no representa la principal fuga de ingresos, por lo que la verdadera oportunidad estratégica radica en impulsar la recurrencia de los clientes Nuevos y elevar la frecuencia de los Esporádicos para maximizar su valor de vida (*CLV*).

El último apartado de este notebook proyecta a seis meses el margen que podría perderse por devoluciones, churn, quejas y descuentos, usando como referencia el promedio de 2024. Estima $554.000 en riesgo, de los cuales $153.000 tienen una causa evitable identificada. El total es una estimación máxima, ya que algunas pérdidas pueden superponerse.

Supuestos de la proyección a 6 meses

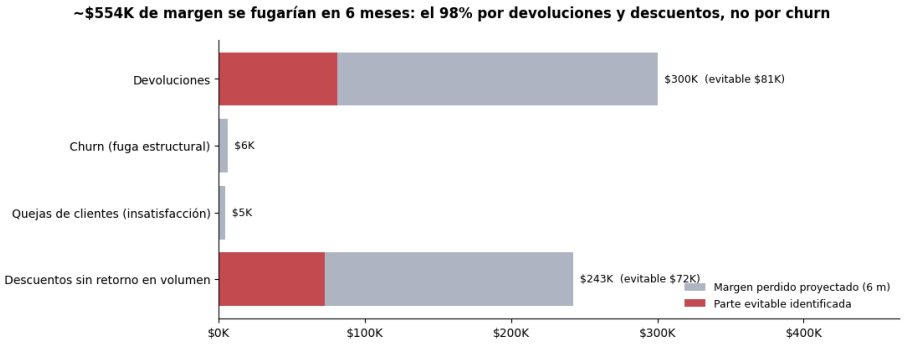
	resultado
Exposición bruta por churn (cota superior)	$722,687
Ventas proyectadas a 6 meses	$4,342,290
Margen neto proyectado a 6 meses	$781,042
Gasto asociado a una queja (USD/cliente)	-59.3
p-valor	0.035
Clientes con queja esperados en 6 meses	432
Se contabiliza como fuga	sí (asociación)

Impacto económico de las fugas a 6 meses (enero–junio de 2025, si nada cambia)

fuga	naturaleza	ingreso_afectado_6m	margen_perdido_6m	evitable_identificado_6m	%_ventas_6m
Devoluciones	Ingreso reembolsado	$645,361	$300,340	$80,824	14.9%
Churn (fuga estructural)	Ingreso no realizado	$36,480	$6,280	—	0.8%
Quejas de clientes (insatisfacción)	Gasto que se deja de hacer	$25,604	$4,605	—	0.6%
Descuentos sin retorno en volumen	Ingreso cedido	$242,500	$242,500	$72,312	5.6%

Generate Code Markdown

La primera tabla resume los supuestos de la proyección: ventas de $4,34 M, margen neto de $781 mil y una exposición bruta por churn de $723 mil. La segunda estima que, en seis meses, devoluciones, churn, quejas y descuentos representarían cerca de $554 mil de margen perdido, con unos $153 mil identificados como potencialmente evitables; las devoluciones y los descuentos son las principales fuentes.



La gráfica proyecta $554 mil de margen en riesgo a seis meses: casi todo proviene de devoluciones y descuentos, mientras churn y quejas tienen un impacto menor. En rojo se muestra la parte evitable identificada: $81 mil en devoluciones y $72 mil en descuentos.

El análisis estima que las principales fugas de margen provienen de las devoluciones y los descuentos, no del churn. Las devoluciones se concentran en Ropa y Electrónica; la fuga de clientes es menor y afecta sobre todo a quienes aún no consolidan el hábito de compra. Por ello, conviene priorizar mejoras en calidad y descripción de productos, controlar los descuentos e impulsar la segunda compra.

A4 - Evaluación de la Efectividad del Marketing

En este apartado se evalúa la conversión por tipo de campaña, canal y segmento, el efecto del descuento ofrecido, el segmento que recibe campañas y no convierte, y el ROI de cada tipo de campaña.

Se heredan dos supuestos de A1: el 77,5 % de las conversiones declaradas (convertido) no tiene una compra real en los 30 días siguientes, por lo que también se usa la conversión verificada; y el descuento ofrecido casi nunca coincide con el aplicado, por lo que el costo de cada campaña se calcula con el descuento ofrecido.

Panorama general y caída de la conversión

En 24 meses se enviaron 8.820 campañas a 4.800 clientes. Cada tipo de campaña sale por un único canal, así que tipo y canal no se pueden analizar por separado.

Embudo de las campañas por año

	2023	2024	Total
envíos	4,368	4,452	8,820
clientes	3,190	3,211	4,800
tasa_apertura	35.6%	36.3%	35.9%
conversión_s/envíos	11.2%	6.9%	9.0%
conversión_s/abiertos	31.6%	18.9%	25.1%
conversión_verificada	2.5%	1.6%	2.0%
descuento_medio	12.6%	12.3%	12.4%

La conversión bajó de 11,2 % en 2023 a 6,9 % en 2024: la caída a la mitad del caso se confirma en proporción, no en nivel (el 22 % no aparece). La apertura (~36 %) y el descuento medio (~12,5 %) no cambiaron; lo que cae es la conversión de quienes abren. Solo el 2,0 % de los envíos tiene conversión verificada, frente al 9,0 % declarado.

Embudo trimestral

fecha_envio	envíos	apertura	conversión	descuento_medio	conv_s/abiertos
2023Q1	1,055	37.8%	11.3%	12.8%	29.8%
2023Q2	1,113	37.1%	12.3%	12.6%	33.2%
2023Q3	1,094	34.3%	11.2%	12.8%	32.5%
2023Q4	1,106	33.2%	10.2%	12.2%	30.8%
2024Q1	1,082	38.5%	7.9%	12.4%	20.6%
2024Q2	1,128	33.7%	6.8%	12.3%	20.3%
2024Q3	1,167	36.7%	7.1%	12.1%	19.4%
2024Q4	1,075	36.3%	5.6%	12.3%	15.4%

Con regresiones logísticas, las odds de convertir caen un 37 % por año (OR = 0,63) con y sin controlar por segmento, tipo y descuento, así que la caída no se debe a la mezcla de envíos. Es un escalón al inicio de 2024: la conversión sobre abiertos pasa de 30–33 % a ~20 %. Como las ventas totales no cayeron (A2), la métrica convertido no refleja ventas reales.

Conversión por tipo de campaña, canal y segmento

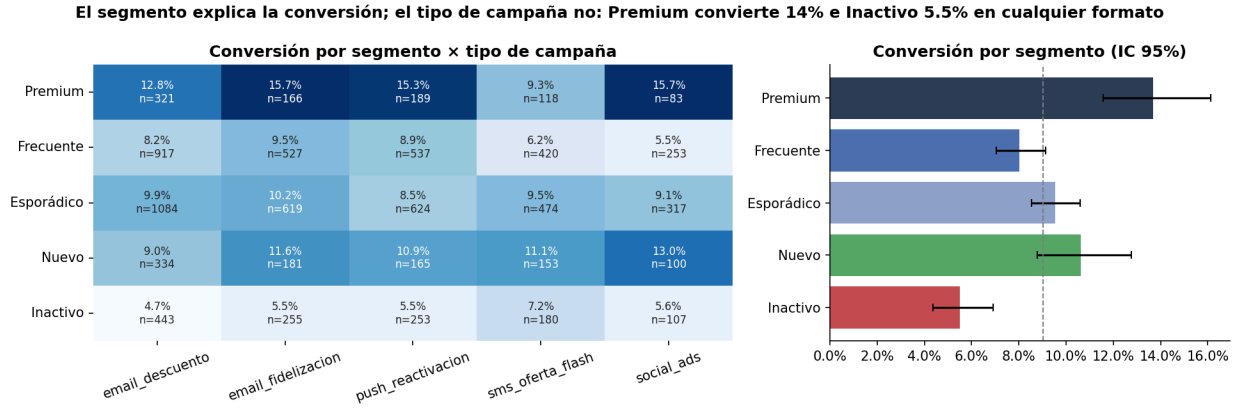
Prueba χ^2 de independencia por dimensión

dimensión	chi2	gl	p_valor	V_Cramer	rango_conversión
tipo_campana	2.9	4	5.75e-01	0.018	8.3% – 10.0%
canal_campana	1.2	3	7.50e-01	0.012	8.3% – 9.2%
segmento	49.0	4	5.93e-10	0.075	5.5% – 13.7%

Apertura y conversión por tipo, canal y segmento (IC 95 % de Wilson)

dimensión	nivel	envíos	conversiones	tasa_apertura	conversión	ic95_inf	ic95_sup	conv_s/abiertos	conv_verificada
tipo_campana	email_descuento	3099	274	35.8%	8.8%	7.9%	9.9%	24.7%	2.2%
	email_fidelizacion	1748	174	35.8%	10.0%	8.6%	11.4%	27.8%	2.5%
	push_reactivacion	1768	162	36.1%	9.2%	7.9%	10.6%	25.4%	1.9%
	sms_oferta_flash	1345	112	35.5%	8.3%	7.0%	9.9%	23.4%	1.6%
	social_ads	860	75	37.0%	8.7%	7.0%	10.8%	23.6%	1.5%
canal_campana	email	4847	448	35.8%	9.2%	8.5%	10.1%	25.8%	2.3%
	push_app	1768	162	36.1%	9.2%	7.9%	10.6%	25.4%	1.9%
	redes_sociales	860	75	37.0%	8.7%	7.0%	10.8%	23.6%	1.5%
	sms	1345	112	35.5%	8.3%	7.0%	9.9%	23.4%	1.6%
segmento	Esporádico	3118	297	37.2%	9.5%	8.5%	10.6%	25.6%	1.0%
	Frecuente	2654	213	35.7%	8.0%	7.1%	9.1%	22.5%	2.9%
	Inactivo	1238	68	34.7%	5.5%	4.4%	6.9%	15.8%	0.2%
	Nuevo	933	99	33.8%	10.6%	8.8%	12.8%	31.4%	0.4%
	Premium	877	120	36.0%	13.7%	11.6%	16.1%	38.0%	7.4%

El tipo de campaña y el canal no influyen en la conversión (8,3 %–10,0 %, p = 0,58; y 8,3 %–9,2 %, p = 0,75). El segmento sí ($p < 10^{-9}$): Premium convierte 13,7 % e Inactivo 5,5 %. Todos abren igual (34 %–37 %); la diferencia está en la compra: Premium convierte el 38 % de lo que abre e Inactivo el 16 %.



Las celdas segmento × tipo parecen mostrar combinaciones ganadoras (Premium con fidelización, 15,7 %), pero la interacción no es significativa (LR = 11,5; p = 0,78) y ninguna celda se aparta de su segmento tras FDR. No hay combinación ganadora: el retorno lo define a quién se envía, no qué ni por dónde.

Efecto del descuento ofrecido sobre la conversión

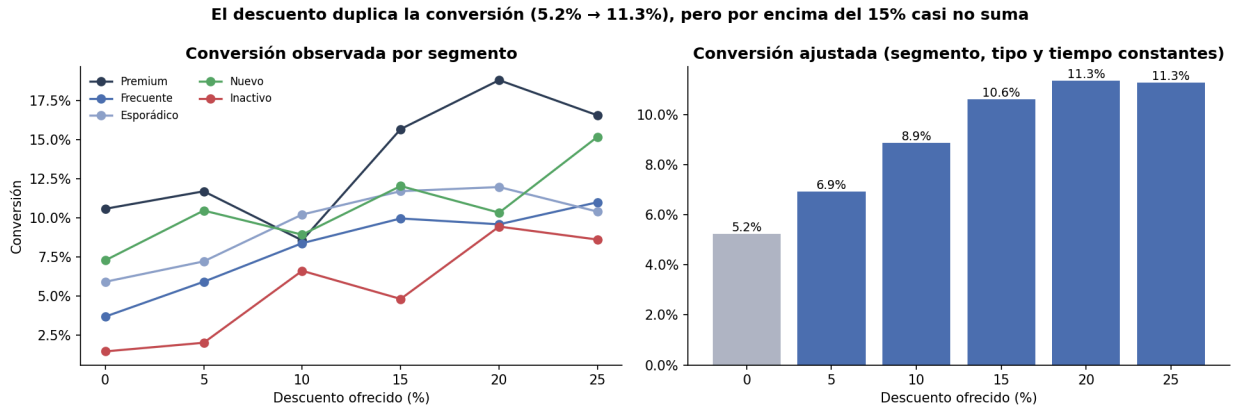
Balance: ¿el descuento depende de lo observable antes del envío?

variable	chi2	gl	p_valor	V_Cramer
segmento	20.0	20	0.460	0.024
tipo_campana	25.2	20	0.192	0.027
anio	3.8	5	0.582	0.021
compras_hist (Kruskal-Wallis)	1.8	5	0.875	nan
gasto_hist (Kruskal-Wallis)	2.7	5	0.748	nan

El nivel de descuento es independiente del segmento, el tipo, el año y la historia del cliente (todos p ≥ 0,19; V de Cramér < 0,03). Se asignó como al azar, por lo que los datos funcionan como un experimento natural y el efecto se puede leer como causal.

Efecto del descuento sobre la conversión por modelo

modelo	OR_por_+5pp	p_valor	efecto_marginal_+5pp	ic95_inf	ic95_sup
Sin controles	1.179	1.16e-13	+1.34%	+0.99%	+1.70%
+ segmento	1.179	1.40e-13	+1.34%	+0.98%	+1.70%
+ segmento + tipo + tiempo	1.175	4.92e-13	+1.30%	+0.95%	+1.66%
Mecanismo: apertura	1.010	4.56e-01	—	—	—
Mecanismo: conversión | abrió	1.217	1.19e-14	—	—	—
Robustez: conversión verificada	1.135	5.48e-03	—	—	—



El descuento sí aumenta la conversión: +1,3 pp por cada +5 pp (OR = 1,18; $p < 10^{-12}$), estable al agregar controles, igual en todos los segmentos (interacción p = 0,15) y confirmado con la conversión verificada (OR = 1,14). No influye en la apertura, sino en la compra de quien abre. Tiene rendimientos decrecientes: la conversión ajustada pasa de 5,2 % sin descuento a 11,3 % con 20 %, y el 25 % no agrega nada. Esto es compatible con A2: el descuento puede activar una compra, pero no sirve como rebaja generalizada.

El segmento que recibe campañas y no convierte

Historia previa (90 días) por segmento

segmento	envíos	conversión	apertura	conv_s_abiertos	tuvo_queja	tuvo_queja_no_resuelta	tuvo_devolución	compras_previas_90d	mediana_días_desde_compra	sin_compra_previa	descuento_medio
Premium	877	13.7%	36.0%	38.0%	4.2%	2.7%	22.5%	2.19	24	7.1%	12.6%
Frecuente	2,654	8.0%	35.7%	22.5%	2.9%	1.8%	14.8%	1.23	44	10.1%	12.4%
Esporádico	3,118	9.5%	37.2%	25.6%	2.6%	1.6%	4.4%	0.32	124	28.8%	12.5%
Nuevo	933	10.6%	33.8%	31.4%	2.6%	1.9%	1.3%	0.15	168	53.5%	12.3%
Inactivo	1,238	5.5%	34.7%	15.8%	2.6%	1.2%	1.7%	0.09	208	60.7%	12.3%

Inactivo recibe el 14 % de los envíos, convierte 5,5 % y necesita 18 envíos por conversión (7 en Premium); de sus 68 conversiones solo 2 son compras reales. Su perfil no es de insatisfacción: tiene las mismas quejas que el resto (2,6

%) y devuelve menos. Lo distingue la desconexión: el 61 % no tiene compras previas y lleva una mediana de 208 días sin comprar.

Contraste de hipótesis (regresión logística con controles, FDR)

hipótesis	OR_total	p_total	OR_Inactivo	p_Inactivo	prevalencia_Inactivo	prevalencia_resto	p_total_FDR
H1 queja reciente	1.15	0.520	0.72	0.755	2.6%	2.9%	0.983
H1b queja no resuelta reciente	0.88	0.666	2.05	0.496	1.2%	1.8%	0.983
H2 devolución reciente	1.00	0.986	0.94	0.955	1.7%	9.7%	0.986
H3 recencia (log días)	0.99	0.786	0.90	0.417	—	—	0.983
H3b sin compra previa	0.93	0.505	1.04	0.889	60.7%	22.8%	0.983

Se contrastaron hipótesis con CRM y devoluciones controlando segmento, tipo, descuento y tiempo: ni las quejas (H1), ni las devoluciones (H2), ni la recencia (H3) explican la no conversión (todos p ≥ 0,41). Inactivo abre al 96 % del nivel del resto pero convierte al 59 %, así que es un problema de baja intención de compra, no de alcance ni de mala experiencia.

ROI por tipo de campaña

El costo del descuento se calculó como d / (1 − d) × monto pagado, sin costos de envío (no hay datos). Se calcularon el ROI sobre ventas (fórmula del enunciado), sobre margen, y el ROI incremental, que solo cuenta las conversiones causadas por el descuento.

ROI contable por tipo de campaña: declarado (ticket del segmento)

tipo_campana	envíos	conversiones	conversión	descuento_medio	venta_decl	costo_desc_decl	margen_decl	ROI_ventas_decl	ROI_margen_decl
social_ads	860	75	8.7%	12.5%	$23,752	$3,793	$4,169	5.3x	1.1x
push_reactivacion	1,768	162	9.2%	12.3%	$51,112	$8,445	$8,746	5.1x	1.0x
email_fidelizacion	1,748	174	10.0%	12.6%	$54,649	$9,277	$9,185	4.9x	1.0x
email_descuento	3,099	274	8.8%	12.5%	$85,763	$14,926	$14,171	4.7x	0.9x
sms_oferta_flash	1,345	112	8.3%	12.2%	$34,874	$6,302	$5,602	4.5x	0.9x
Total	8,820	797	9.0%	12.4%	$250,149	$42,743	$41,872	4.9x	1.0x

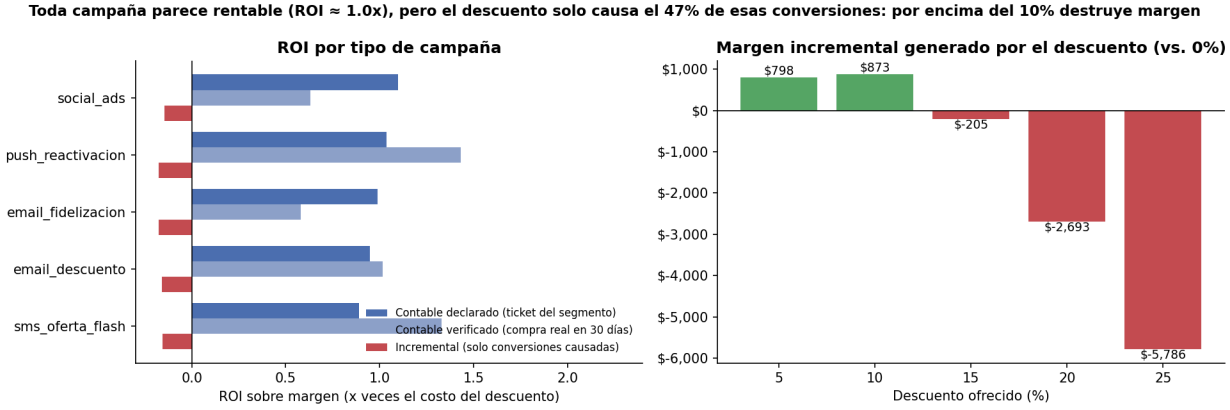
Con la fórmula del enunciado todas las campañas rinden ~**4,9x**, pero sobre margen apenas **1,0x** (0,9x con compras verificadas): $42.700 de descuento para $41.900 de margen. Ningún tipo se distingue (0,9x–1,1x).

ROI incremental por tipo de campaña

tipo_campana	envíos_con_descuento	conversiones_incrementales	%_conv_incrementales	costo_descuento	margen_incremental	ROI_incremental
social_ads	733	32.1	47%	$3,981	$-581	-0.15x
sms_oferta_flash	1,124	47.1	46%	$5,933	$-931	-0.16x
email_descuento	2,596	116.4	47%	$14,677	$-2,313	-0.16x
push_reactivacion	1,441	67.5	47%	$8,690	$-1,521	-0.17x
email_fidelizacion	1,445	73.2	47%	$9,440	$-1,666	-0.18x
Total	7,339	336.3	47%	$42,721	$-7,013	-0.16x

ROI incremental por nivel de descuento

desc_pct	envíos_con_descuento	conversiones_incrementales	%_conv_incrementales	costo_descuento	margen_incremental	ROI_incremental
5	1,504	25.5	25%	$1,911	$798	+0.42x
10	1,456	52.5	41%	$4,706	$873	+0.19x
15	1,467	79.6	51%	$8,656	$-205	-0.02x
20	1,454	89.6	54%	$12,204	$-2,693	-0.22x
25	1,458	89.1	54%	$15,244	$-5,786	-0.38x



Solo el 47 % de las conversiones con descuento es causado por el descuento; el resto habría comprado igual. El ROI incremental es de −0,16x (−$7.000 en 24 meses) y es casi igual en todos los tipos. Lo que cambia la economía es el nivel: 5 % y 10 % generan margen (+0,42x y +0,19x), 15 % es el equilibrio y 20 %–25 % lo destruyen.

Escenario: tope de descuento del 10 % en campañas

	Actual	Tope 10%	diferencia	diferencia_6m	variación_%
conversiones (24 m)	721	623	-98	-24	-13.6%
costo del descuento (24 m)	$42,721	$20,989	$-21,731	$-5,433	-50.9%
margen de campañas (24 m)	$33,831	$45,168	$11,338	$2,834	+33.5%

Un tope del 10 % en campañas bajaría las conversiones un 14 %, pero el costo del descuento caería un 51 % y el margen de campañas subiría un 34 % (+$2.800 por semestre). Con márgenes bajos como el de Electrónica (≤ 14 %), ningún descuento es rentable. Es una fuga pequeña frente a devoluciones y descuentos en caja (A3), pero repite el mismo patrón de descuento sin control.

Conclusiones de A4

- La conversión cayó a la mitad por un escalón en 2024 en la compra de quien abre, no por apertura ni mezcla; solo el 22,5 % de las conversiones se verifica con una compra.
- Tipo y canal no influyen; el segmento decide (Premium 13,7 %, Inactivo 5,5 %). No hay combinación ganadora.
- El descuento causa conversión (+1,3 pp por +5 pp), con techo en el 15–20 %.
- Inactivo recibe campañas y no convierte por baja intención de compra, no por quejas ni devoluciones.
- El ROI contable (~1x sobre margen) engaña: el incremental es −0,16x y el descuento solo crea margen hasta el 10 %.

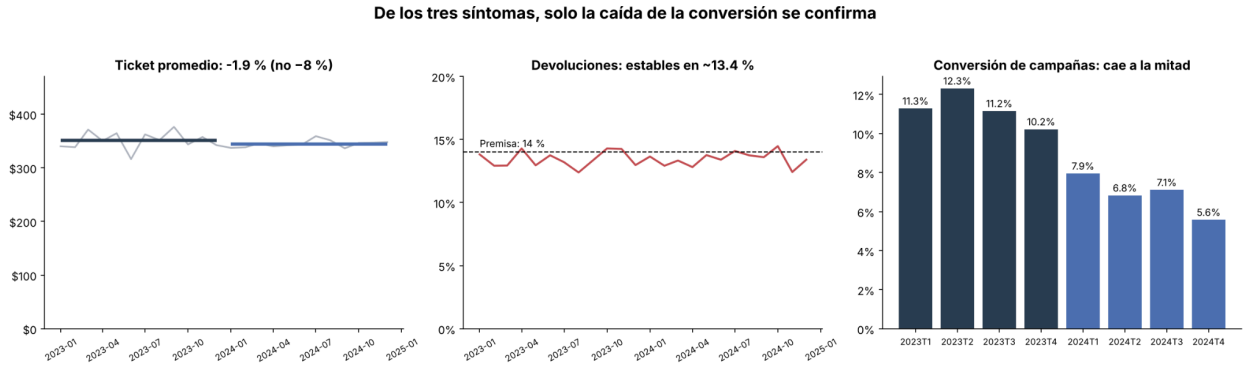
Estas conclusiones alimentan las acciones de A5: tope del 10 % al descuento de campañas, reasignar envíos de Inactivo a Premium y medir con grupo de control y conversión verificada.

A5 - Storytelling Ejecutivo y Recomendaciones

En este apartado se conectan los hallazgos de A1–A4 en un solo relato y se cuantifican tres recomendaciones con la forma que pide el enunciado: "Si hacemos X, esperamos un incremento de Y % en Z métrica, equivalente a [monto]". Todo el cálculo está en el notebook 05_recomendaciones.ipynb, que lee los datos limpios de data/clean y las tablas de A2–A4, para que cada cifra de la presentación sea reproducible.

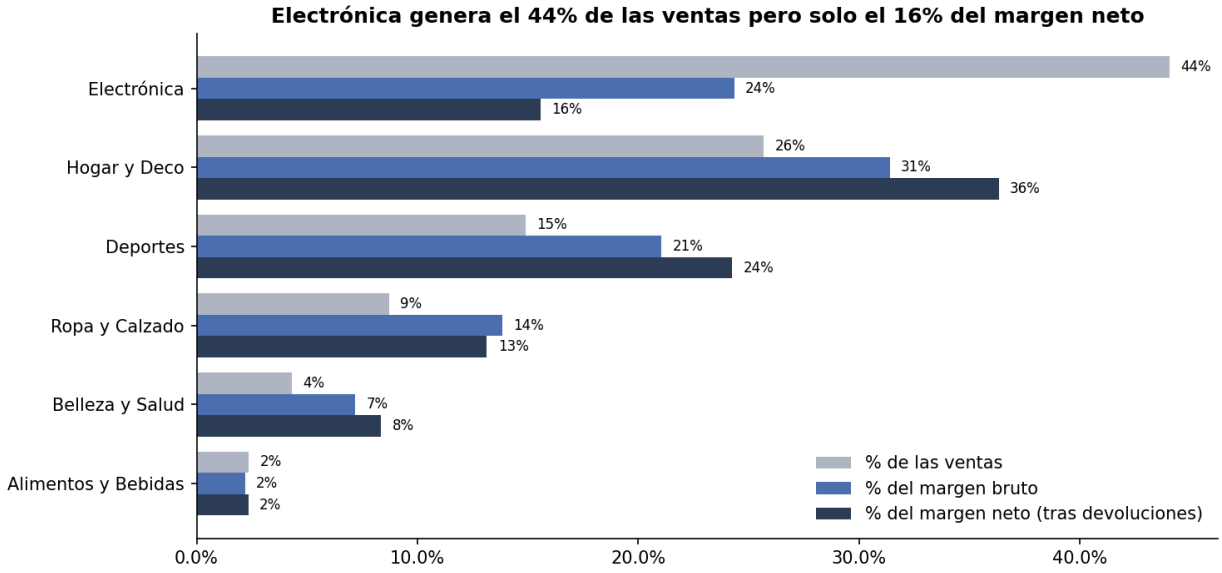
La idea central del relato es que la gerencia cree que el problema es la pérdida de clientes, pero los clientes son leales. El margen se pierde por qué se vende (Electrónica y Ropa, con muchas devoluciones), por cómo se vende (descuentos que no generan volumen, sobre todo en el canal online) y por clientes nuevos que no llegan a una segunda compra.

El caso parte de tres síntomas: una caída del 8 % en el ticket promedio, devoluciones del 14 % y una conversión de marketing que bajó del 22 % al 11 %. Antes de construir la historia se verificó cada síntoma sobre los datos limpios, para que el relato no partiera de premisas que los datos no sostienen.

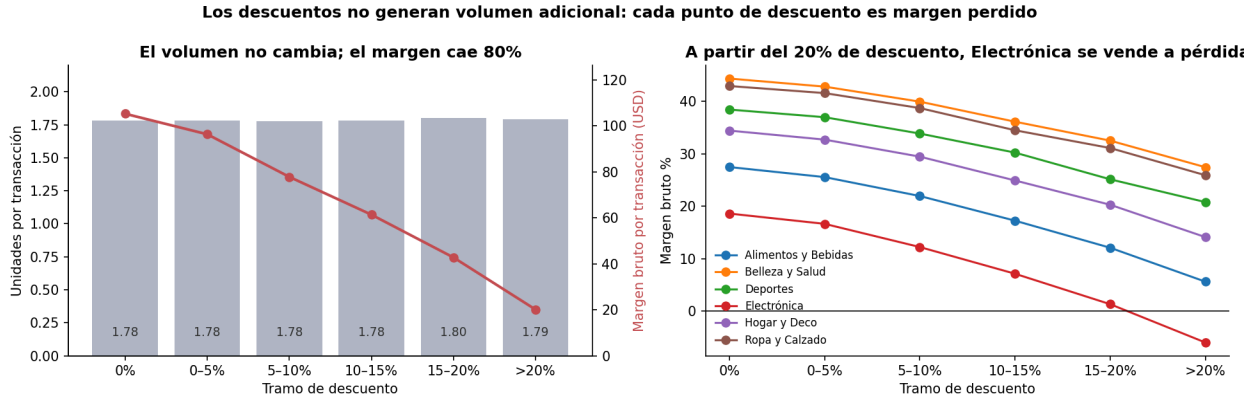


La gráfica muestra los tres síntomas en los 24 meses. El ticket promedio baja apenas un 1,9 %, no un 8 %. Las devoluciones se mantienen en ~13,4 % todo el período, sin subir en el último trimestre. La conversión sí cae a la mitad: de 11,3 % a 5,6 % entre el primer y el último trimestre. Por eso el relato no parte de las premisas del caso, sino de lo que los datos confirman.

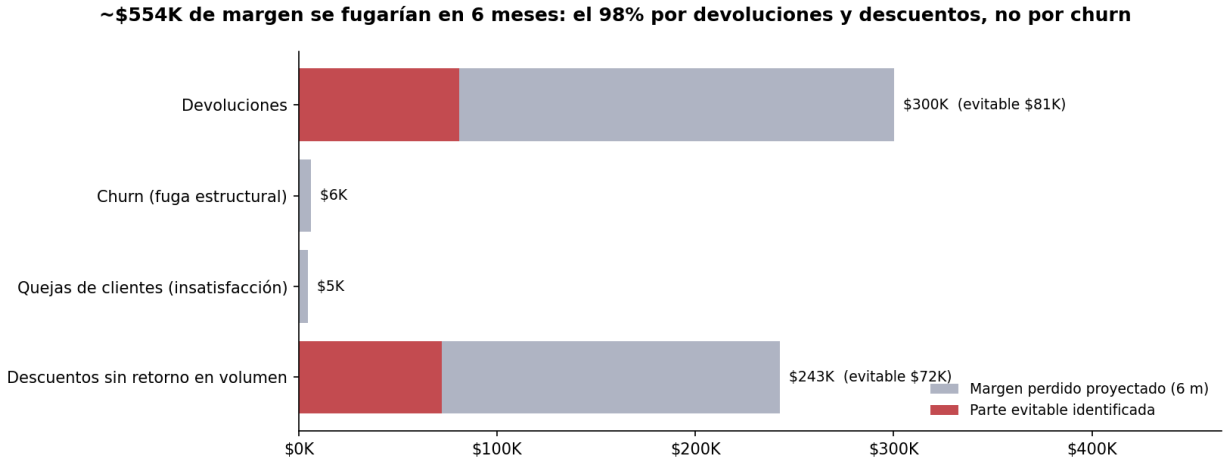
- El primer hallazgo es que lo que más se vende no es lo que más deja. Electrónica genera el 44 % de las ventas, pero solo el 16 % del margen neto, porque tiene un margen bajo (6,3 %) y la segunda tasa de devolución más alta (17,7 %).



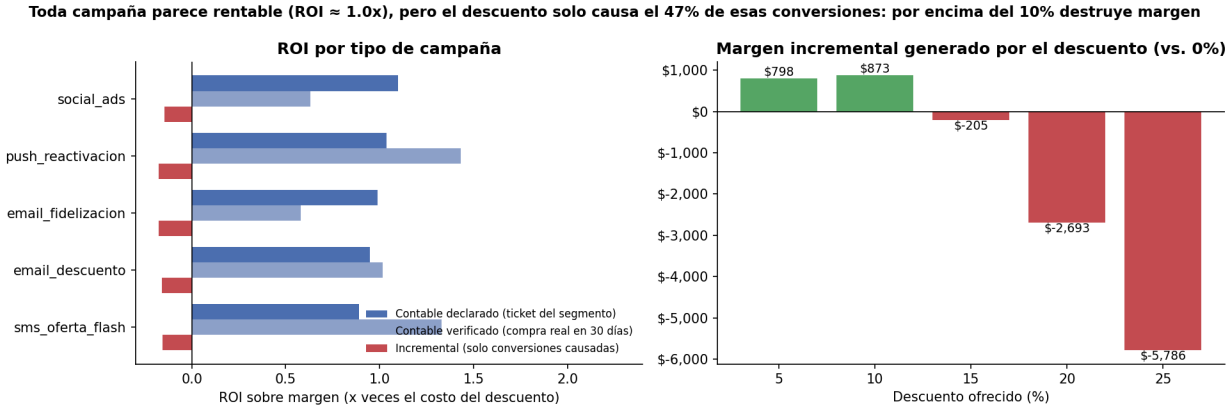
El segundo hallazgo es que los descuentos no compran volumen. En A2 el efecto del descuento sobre las unidades vendidas fue de +0,2 %, no significativo en cuatro pruebas distintas, mientras que los descuentos costaron $968K, el 22,5 % del margen bruto. Por encima del 20 % de descuento, Electrónica se vende a pérdida.



El tercer hallazgo junta todas las fugas de A3 en una sola cifra. En seis meses se perderían cerca de $554K de margen, y el 98 % se debe a devoluciones y descuentos. La fuga de clientes de alto valor y las quejas apenas suman $11K. De ese total, $153K son evitables con acciones ya identificadas.



El cuarto hallazgo explica la caída de marketing. En A4 se vio que el tipo de campaña y el canal no influyen en la conversión, que la decide el segmento, y que el 53 % de los convertidos habría comprado sin descuento. Por eso el ROI parece rentable en lo contable (~1x sobre margen), pero es negativo cuando se mide solo lo que el descuento causa (−0,16x). El descuento solo crea margen hasta el 10 %.



Debido a este análisis, se da una lista de recomendaciones a seguir

- **Tope de descuento del 10% en ventas.**

los descuentos no generan volumen y por encima del 20 % Electrónica vende a pérdida. Además, el canal online descuenta el doble que la tienda (7,5 % frente a 3,7 %).
Para calcular el impacto se tomó cada venta no devuelta y se recuperó la parte del descuento que excede el tope, es decir, (descuento − tope) × ingreso bruto. Las ventas devueltas se excluyen, porque al reembolsar el monto el descuento no cambia el margen. Se probaron tres topes: 10 %, 15 % y 20 %.
El supuesto clave es que el volumen no cae al limitar el descuento. Como es el supuesto más débil, también se calculó la pérdida de volumen de equilibrio: cuánto volumen podrían perder las ventas afectadas antes de que la

medida deje de convenir.

	tope	ventas_afectadas_%	margen_recuperado_6m	impacto_%_margen_neto	pérdida_volumen_equilibrio_%
0	10%	19.0	47619.1	6.1	32.8
1	15%	10.5	18190.1	2.3	31.0
2	20%	3.8	4060.0	0.5	31.6

En la tabla se ve que el tope del 10 % afecta al 19 % de las ventas y recupera ≈ $47,6K de margen por semestre, +6,1 % del margen neto. La última columna muestra que la medida sigue conviniendo aunque esas ventas perdieran hasta un 33 % de su volumen. Como A2 no encontró ninguna respuesta del volumen al descuento, el riesgo es bajo. Un tope del 20 % solo elimina las ventas a pérdida y recupera mucho menos.

- **Reducir las devoluciones por defecto en Electrónica y por defecto o talla en Ropa**

En A3 se encontró que las devoluciones se explican por la categoría y no por el cliente ni el canal: Ropa y Calzado tiene 21,8 % y Electrónica 17,7 %, frente a ~10 % en el resto. En A5 se bajó un nivel más para responder qué motivo de devolución cuesta más margen.
El margen perdido por cada devolución se calculó como el margen bruto menos el margen neto de la venta devuelta, es decir, lo reembolsado menos el costo recuperado. Cuando el motivo es producto defectuoso o fraude, el producto no vuelve al inventario (supuesto de A1), por eso esos motivos cuestan mucho más.

	categoria	motivo_devolucion	devoluciones	margen_perdido_24m	%_del_total
23	Electrónica	Producto_defectuoso	408	392017.8	33.0
29	Hogar_y_Deco	Producto_defectuoso	232	114766.0	9.7
35	Ropa_y_Calzado	Producto_defectuoso	512	86603.3	7.3
17	Deportes	Producto_defectuoso	262	74603.0	6.3
22	Electrónica	No_cumple_expectativas	578	74516.6	6.3
28	Hogar_y_Deco	No_cumple_expectativas	329	53682.8	4.5
21	Electrónica	Fraude_reportado	58	42038.1	3.5
16	Deportes	No_cumple_expectativas	323	34679.9	2.9

La acción propuesta es control de calidad con los proveedores de Electrónica (auditar los productos con más defectos y exigir garantía o reposición al proveedor) y guía de tallas y control de calidad en Ropa. No hay un dato externo que diga cuánto bajan las devoluciones con estas medidas, así que el impacto se presenta como escenario con sensibilidad.

	reducción_de_esas_devoluciones	margen_recuperado_6m	impacto_%_margen_neto
0	Margen perdido hoy (6 m)	125497.7	16.1
0	15 %	18824.7	2.4
1	30 % (escenario central)	37649.3	4.8
2	50 %	62748.9	8.0

En la tabla se ve que esas tres combinaciones hacen perder ≈ $125K de margen por semestre, el 16 % del margen neto. Reducirlas un 30 % recupera ≈ $37,6K por semestre (+4,8 % del margen neto); con una reducción más conservadora del 15 % serían $18,8K y con una del 50 %, $62,7K.

- **Campañas: tope de descuento del 10 % y sacar a los Inactivos del envío masivo**

En A4 se encontró que el descuento de campaña sí sube la conversión (+1,3 pp por cada +5 pp de descuento), pero el 53 % de los convertidos habría comprado sin él, así que el ROI incremental es negativo (−0,16x) y el descuento solo crea margen hasta el 10 %. Además, el segmento Inactivo recibe el 14 % de los envíos y es el que menos convierte, por baja intención de compra (61 % sin compras previas) y no por quejas ni devoluciones.

	concepto	valor
0	Margen de campañas hoy (6 m)	8457.7
1	Margen de campañas con tope 10 % (6 m)	11292.1
2	Variación del margen de campañas	33.5
3	Costo de descuento evitado (6 m)	5432.8
4	Conversiones perdidas (6 m)	24.5
5	% de envíos a Inactivo	14.0
6	Conversión de Inactivo	5.5
7	Conversión del resto	9.6

En la tabla se ve que con el tope del 10 % el margen de campañas sube un 34 % (+$2,8K por semestre) y se dejan de regalar ≈ $5,4K en descuentos, a cambio de unas 24 conversiones menos que en su mayoría habrían comprado igual. Los envíos a Inactivo, que convierten 5,5 %, se pueden reasignar a Premium, que convierte 13,7 %, 2,5 veces más.

En monto es la recomendación más pequeña, porque las campañas mueven poco dinero, pero es la que corrige el síntoma que la gerencia sí había detectado, la caída de la conversión.

© UCAB, 2026